




Projet d'Économétrie Appliquée



Tesla Inc. : Analyse du risque boursier d'une entreprise à haute volatilité

Master 1 MBFA - Analyse des Risques de Marché

Arthur GIRAUD et Rehan MASOOD

Année Universitaire 2024-2025

Table des matières

Remerciements	3
Avant-propos	4
Préambule	5
Abstract	6
1. Présentation de Tesla Inc.	7
1.1 Historique de l'entreprise	7
1.2 Elon Musk : rôle et impact sur la volatilité	8
1.3 Modèle économique de Tesla Inc.	8
1.4 Événements marquants influençant le cours de l'action Tesla	9
1.5 Évolution du cours boursier	10
2. Enjeux écologiques et innovation	12
2.1 Tesla et la transition énergétique mondiale	12
2.2 Technologies propres (Gigafactory, batteries, solaire)	12
2.3 Impacts environnementaux (production, recyclage, lithium)	13
2.4 Benchmark : Rivian, BYD, Nio	13
3. Contexte Macroéconomique et Géopolitique	15
3.1 Taux d'intérêt, Inflation, Pétrole	15
3.2 Subventions et Politique Fiscale Américaine	15
3.3 Conflits Commerciaux	16
4. Analyse financière de Tesla Inc.	17
4.1 Répartition du CA	17
4.2 Données financières	18
5. Partie empirique – Analyse et modélisation de la volatilité	20
5.1 Préparation des données	20
5.1.1 Présentation des données	20
5.1.2 Transformation logarithmique	20
5.1.3 Corrélogramme du logarithme de Tesla	21
5.2 Analyse de la stationnarité	22
5.2.1 Test de Dickey-Fuller augmenté	22
5.2.2 Test de Phillips-Perron	24
5.2.3 Test de Kwiatkowski–Phillips–Schmidt–Shin	25
5.3 Stationnarisation de la série	26
5.3.1 Passage à la différence première	26
5.3.2 Analyse descriptive des rendements stationnarisés	27
5.3.3 Vérification de la stationnarité	28
5.4 Estimation des modèles ARMA	29
5.5 Estimation des modèles ARCH	30
5.5.1 Modèle GARCH	30
5.5.2 Modèle GJR-GARCH	33
5.5.3 Modèle EARCH	34
5.5.4 Intégration de distributions alternatives : Loi de Student et GED	35
5.6 Value at Risk (VaR)	37

5.6.1 Définition	37
5.6.2 Pourquoi utilise-t-on la VaR ?	37
5.6.3 Construction de la VaR	38
5.6.4 Calcul de la VaR	38
5.6.5 Backtesting de la VaR	39
5.6.6 Test de Kupiec	41
5.7 Robustness check	42
5.7.1 Analyse de la stationnarité	42
5.7.2 Estimation du meilleur modèle ARMA	43
5.7.3 Estimation du meilleur modèle ARCH	44
5.7.4 Value at Risk	45
5.7.5 Backtesting	46
5.7.6 Conclusion du Robustness check	47
6. Conclusion	48
7. Bibliographie	50
8. Annexes	51

Remerciements

Nous remercions chaleureusement Monsieur François Benhmad, responsable du parcours *Analyse des risques de marché*, pour la qualité de son encadrement, la clarté de ses explications et la rigueur méthodologique transmise tout au long du semestre. Son accompagnement a grandement contribué à la réalisation de ce projet.

Nous tenons également à remercier l'ensemble de nos camarades de la promotion *Analyse des risques de marché* pour les échanges constructifs, les discussions collectives et l'entraide dont chacun a fait preuve au cours de cette période de travail. Leur esprit collaboratif et leur engagement ont largement contribué à créer un environnement de travail stimulant et bienveillant.

Ce projet est le fruit d'un effort collectif et d'un apprentissage continu, auquel toutes ces personnes ont apporté leur contribution directe ou indirecte, et nous leur en sommes profondément reconnaissants.

Avant-propos

Ce projet a été réalisé dans le cadre de notre année de Master 1 en *Finance de Marché*. Il reflète notre volonté commune d'approfondir notre compréhension des marchés financiers et d'appliquer de manière concrète les outils d'analyse économétrique étudiés au cours de notre formation.

Nous avons choisi d'orienter notre travail sur l'entreprise *Tesla Inc.*, en raison de son caractère unique à la fois sur le plan technologique, financier et stratégique. Son positionnement hybride, entre innovation industrielle, disruption numérique et spéculation boursière, nous a paru particulièrement riche d'enseignements pour une étude approfondie du risque de marché.

L'action Tesla, connue pour sa forte volatilité, représente un cas idéal pour mettre en œuvre des modèles économétriques de mesure du risque, notamment à travers le calcul de la *Value at Risk* (VaR) et l'utilisation de modèles de type GARCH. Ce travail nous a permis de développer nos compétences analytiques, tout en portant un regard critique sur les limites de ces outils face à des actifs à comportement atypique.

Préambule

L'évolution des marchés financiers au cours des dernières décennies a profondément transformé les méthodes d'analyse du risque, rendant indispensables des outils économétriques de plus en plus sophistiqués. Dans un contexte marqué par l'incertitude macroéconomique, les chocs géopolitiques et l'émergence de nouveaux secteurs technologiques, il devient essentiel de mieux comprendre les dynamiques qui influencent la volatilité des actifs cotés.

Ce projet s'inscrit dans cette perspective. Il propose une étude approfondie du risque de marché associé à *Tesla Inc.*, entreprise emblématique de la transition énergétique et de l'innovation technologique. Plus qu'un simple constructeur automobile, Tesla est devenue un symbole des valeurs de croissance à forte intensité spéculative, exposée à la fois aux fluctuations des marchés et aux décisions stratégiques de son dirigeant.

À travers ce travail, nous mobilisons des outils d'économétrie financière notamment les modèles GARCH pour modéliser la volatilité de l'action Tesla et en évaluer la *Value at Risk*. Ce projet vise à combiner rigueur quantitative et réflexion stratégique, dans le but de mieux appréhender les enjeux liés à la gestion du risque dans un environnement financier en constante évolution.

Abstract

Ce projet porte sur l'analyse du risque de marché associé à l'action *Tesla Inc.*, l'un des titres les plus volatils et médiatisés des marchés financiers mondiaux. Acteur majeur du secteur des véhicules électriques et des énergies renouvelables, Tesla incarne à la fois le potentiel de l'innovation technologique et les limites d'une valorisation souvent spéculative.

Notre objectif est de répondre à la problématique suivante :

Les modèles économétriques traditionnels sont-ils assez performants pour mesurer le risque d'une action comme Tesla, un actif hautement volatil et fortement influencé par des facteurs exogènes ?

Pour cela, nous mobilisons des outils économétriques avancés, en particulier les modèles de la famille GARCH, permettant d'estimer la volatilité conditionnelle des rendements boursiers. À partir de données journalières issues de Yahoo Finance, nous calculons une *Value at Risk* (VaR) paramétrique, puis procédons à un *backtesting* afin d'évaluer la précision et la robustesse des modèles sélectionnés.

Au-delà de l'approche statistique, nous étudions le contexte macroéconomique et géopolitique dans lequel évolue l'entreprise : chocs de taux d'intérêt, inflation, prix de l'énergie, politiques industrielles américaines (comme l'*Inflation Reduction Act*), ainsi que les tensions commerciales avec la Chine et l'Europe. Nous analysons également la sensibilité de Tesla aux facteurs de sentiment de marché, notamment ceux liés à la communication directe et souvent imprévisible de son dirigeant Elon Musk.

Nos résultats mettent en évidence une forte exposition au risque de marché, ainsi que les limites des modèles traditionnels pour évaluer des titres à forte volatilité. Ce travail illustre l'application concrète de l'économétrie financière à l'étude d'une entreprise emblématique de notre époque, tout en soulignant l'importance d'adapter les outils d'analyse aux spécificités du marché étudié.

1. Présentation de Tesla Inc.

1.1 Historique de l'entreprise

Tesla Inc. est fondée en juillet 2003 à San Carlos, en Californie, par deux ingénieurs passionnés d'énergies renouvelables : Martin Eberhard et Marc Tarpenning. L'objectif initial est ambitieux : révolutionner l'industrie automobile en produisant un véhicule 100% électrique performant, sans compromis sur le design ou l'autonomie. L'entreprise tire son nom du célèbre inventeur Nikola Tesla, pionnier de l'électricité et du courant alternatif.

En 2004, l'entrée d'Elon Musk au capital marque un tournant stratégique. À l'époque, Musk investit 6,5 millions de dollars dans la série A de financement et devient président du conseil d'administration. Bien qu'il ne soit pas le fondateur au sens juridique, il est aujourd'hui considéré comme la figure emblématique de la marque, notamment depuis sa prise de fonction comme CEO en 2008, après l'éviction d'Eberhard. Musk impose alors une culture d'innovation, d'intégration verticale et de prise de risques technologiques rarement observée dans l'industrie automobile.

Le premier véhicule commercialisé par Tesla est le Tesla Roadster, lancé en 2008. Il s'agit d'une voiture de sport 100% électrique basée sur un châssis de Lotus Elise, équipée d'un moteur électrique au lithium-ion — une première mondiale à cette époque. Bien que le Roadster ne soit produit qu'à environ 2 500 exemplaires, il prouve la faisabilité d'un véhicule électrique haut de gamme et positionne Tesla comme un acteur crédible.

Tesla connaît des difficultés financières chroniques jusqu'en 2010, année de son introduction en bourse sur le NASDAQ. L'entreprise lève 226 millions de dollars lors de son IPO, devenant ainsi la première entreprise automobile américaine à entrer en bourse depuis Ford en 1956. Cette opération donne à Tesla les moyens de lancer des projets plus ambitieux.

En 2012, la sortie du Model S, une berline haut de gamme 100% électrique, constitue un tournant majeur. Ce véhicule, salué pour son autonomie, sa sécurité et ses performances, connaît un succès critique et commercial important. Il est suivi en 2015 du SUV Model X, puis du très populaire Model 3 en 2017, destiné à un public plus large grâce à son prix plus abordable (environ 35 000\$ à son lancement).

En parallèle, Tesla se lance dans la construction de ses propres usines de production à grande échelle, appelées Gigafactories, avec un premier site au Nevada en 2016, suivi par Shanghai (2019), Berlin (2021) et Austin, Texas (2022). Cette stratégie d'intégration verticale permet à Tesla de mieux contrôler ses coûts, sa production de batteries et ses marges, tout en réduisant sa dépendance aux fournisseurs extérieurs.

En 2016, Tesla fusionne avec SolarCity, une entreprise de panneaux solaires fondée par les cousins d'Elon Musk. Ce rachat illustre la volonté de Tesla de devenir un acteur global de l'énergie durable. La société développe également des produits comme le Powerwall (batterie résidentielle) ou le Megapack (solution de stockage à grande échelle pour les réseaux).

Enfin, Tesla investit massivement dans les logiciels et l'intelligence artificielle, avec le développement de l'Autopilot, du Full Self Driving (FSD), et plus récemment du projet Tesla Bot (robot humanoïde) et du supercalculateur Dojo, conçu pour l'apprentissage profond et la conduite autonome.

En 2025, Tesla est l'un des constructeurs automobiles les plus valorisés au monde, avec une capitalisation boursière avoisinant les 600 à 800 milliards de dollars selon les fluctuations de marché. L'entreprise emploie plus de 140 000 personnes dans le monde (Tesla, 2023) et continue de jouer un rôle central dans la transition énergétique, la mobilité électrique et l'IA industrielle.

1.2 Elon Musk : rôle et impact sur la volatilité

Depuis sa prise de contrôle de Tesla Inc., Elon Musk est devenu l'un des PDG les plus médiatisés, controversés et influents du XXI^e siècle. Son rôle dépasse largement celui d'un simple chef d'entreprise : il incarne la marque Tesla, agit comme principal moteur de la stratégie de l'entreprise, et influence directement la perception qu'en ont les investisseurs. Cette concentration du pouvoir décisionnel et médiatique autour de sa personne a un effet direct sur la volatilité du cours de l'action Tesla.

Elon Musk se distingue par un style de management non conventionnel, caractérisé par une prise de risque importante, une communication directe sur les réseaux sociaux, et une volonté affirmée de disrupter les industries traditionnelles. Ces qualités ont permis à Tesla de s'imposer comme une entreprise technologique de premier plan, mais ont également accentué les risques liés à sa gouvernance.

Le PDG de Tesla prend fréquemment des décisions stratégiques à haute visibilité : construction de Gigafactories, développements de véhicules autonomes, projets futuristes comme le robot humanoïde Tesla Bot ou le supercalculateur Dojo. Ces annonces, souvent médiatisées via son compte Twitter (désormais X), génèrent régulièrement des réactions immédiates du marché.

L'impact d'Elon Musk sur la volatilité de l'action Tesla est bien documenté. Par exemple, le 1^{er} mai 2020, Musk tweete : "Tesla stock price is too high imo". En quelques heures, l'action perd plus de 10% de sa valeur. D'autres tweets, comme celui affirmant vouloir retirer Tesla de la bourse ("funding secured", août 2018), ont également provoqué des remous boursiers majeurs, au point d'attirer l'attention de la SEC (Securities and Exchange Commission).

Des études empiriques, confirment que les tweets d'Elon Musk ont un effet statistiquement significatif sur les rendements et la volatilité intrajournalière de l'action Tesla, indépendamment de l'information fondamentale.

Dans la littérature financière, on parle parfois de "CEO risk premium" pour désigner l'impact que peut avoir un dirigeant sur la prime de risque exigée par les investisseurs. Dans le cas de Tesla, la centralité d'Elon Musk dans la stratégie, la communication et l'innovation crée un risque spécifique : la perception de l'entreprise peut varier fortement en fonction de sa crédibilité ou de ses décisions personnelles.

Ce phénomène de personnalisation extrême est rare à cette échelle dans les marchés financiers. Il constitue un facteur structurel de volatilité, qui doit être intégré dans toute analyse de la Value at Risk (VaR) de l'action Tesla.

1.3 Modèle économique de Tesla Inc.

Tesla Inc. ne se définit pas uniquement comme un constructeur automobile : c'est une entreprise technologique intégrée, opérant dans l'automobile, l'énergie, le logiciel et plus récemment l'intelligence artificielle. Son modèle économique repose sur trois piliers interdépendants : la vente directe de véhicules électriques, les solutions énergétiques décentralisées, et les revenus issus des logiciels embarqués.

Contrairement aux constructeurs traditionnels, Tesla adopte une stratégie d'intégration verticale très poussée : l'entreprise conçoit ses propres batteries, développe ses logiciels propriétaires, gère ses propres usines (Gigafactories), et vend directement ses véhicules via son site web et ses showrooms, sans passer par un réseau de concessionnaires.

Cette stratégie permet à Tesla de réduire ses coûts marginaux, d'accélérer ses cycles d'innovation, et de maîtriser la totalité de la chaîne de valeur, depuis les matières premières (lithium,

cobalt, etc.) jusqu'à l'expérience client. Elle s'illustre par la multiplication des Gigafactories, qui produisent à la fois les cellules de batteries, les véhicules et les systèmes de stockage d'énergie.

La principale source de revenus de Tesla reste la vente de voitures électriques. En 2023, l'entreprise a vendu plus de 1,8 million de véhicules, avec le Model 3 et le Model Y représentant plus de 80% des ventes globales. Ces modèles sont conçus pour un marché de masse, contrairement aux premiers modèles haut de gamme (Roadster, Model S, Model X).

Tesla tire également des revenus des crédits carbone (ZEV credits) vendus à d'autres constructeurs qui ne respectent pas les normes environnementales. Bien que déclinant en proportion, ces revenus restent significatifs et peuvent booster ponctuellement les résultats trimestriels.

Tesla commercialise plusieurs fonctionnalités logicielles payantes, comme Autopilot et Full Self-Driving (FSD). Ces options, facturées entre 6 000\$ et 15 000\$ selon les versions, sont installées à distance sur les véhicules déjà vendus. Ce modèle permet à Tesla de générer des marges extrêmement élevées sur des revenus logiciels récurrents, sans coûts de production physiques supplémentaires. À cela s'ajoute la collecte de données massives à travers sa flotte de véhicules (fleet learning), qui alimente l'entraînement des algorithmes de conduite autonome grâce à son supercalculateur Dojo. Cette intégration technologique renforce la position de Tesla en tant qu'acteur émergent dans le domaine de l'intelligence artificielle appliquée à la mobilité.

Le segment Tesla Energy comprend la vente de panneaux solaires (Solar Roof), de batteries résidentielles (Powerwall) et industrielles (Megapack). Ces solutions permettent aux particuliers et aux entreprises de produire, stocker et consommer leur propre électricité de manière autonome et décarbonée. Même si ce segment ne représente encore qu'environ 5 à 6% du chiffre d'affaires total, il est stratégique pour Elon Musk, qui considère Tesla comme une entreprise énergétique autant qu'un constructeur automobile. Le développement des Megapack, destinés à stabiliser les réseaux électriques, connaît une expansion significative aux États-Unis, en Australie et en Europe.

1.4 Événements marquants influençant le cours de l'action Tesla

Le cours boursier de Tesla Inc. est fortement influencé par une combinaison d'éléments fondamentaux, de décisions stratégiques, de phénomènes de marché, et d'annonces médiatiques souvent liées à la figure d'Elon Musk. Certains événements spécifiques ont provoqué des variations brutales du prix de l'action, amplifiant sa volatilité et rendant nécessaire une évaluation rigoureuse du risque pour les investisseurs.

Tesla Inc. a procédé à deux splits d'actions récents dans le but affiché de rendre le titre plus accessible aux investisseurs particuliers. Le premier, un fractionnement de 5 pour 1, a eu lieu le 31 août 2020, dans un contexte de forte appréciation boursière (+700% en un an). Le second, réalisé le 25 août 2022, a pris la forme d'un split de 3 pour 1. Bien que ces opérations n'aient aucun impact sur les fondamentaux de l'entreprise, elles augmentent la liquidité du titre et favorisent la spéculation à court terme, notamment sur les plateformes de trading sans frais comme Robinhood. Ce phénomène renforce l'attrait du titre auprès d'un public plus large, mais contribue également à accentuer la volatilité.

Les publications de résultats trimestriels jouent un rôle central dans les mouvements de l'action. À titre d'exemple, l'annonce d'un bénéfice surprise au deuxième trimestre 2020 – le quatrième consécutif – a permis à Tesla de devenir éligible à l'indice SP 500, déclenchant une hausse spectaculaire de son cours. De même, au quatrième trimestre 2021, un chiffre d'affaires record et une marge brute automobile dépassant 30% ont propulsé le titre au-delà de 1 000 dollars. Toutefois,

d'autres publications ont suscité des corrections notables, notamment en cas de bénéfices décevants, de livraisons inférieures aux attentes ou de communications jugées floues.

Les annonces technologiques et les lancements de produits participent également à la volatilité du titre. La présentation du Cybertruck en novembre 2019, marquée par une démonstration ratée du « verre incassable », a provoqué une réaction mitigée du marché. Les événements Tesla AI Day (2021 et 2022), centrés sur les avancées en intelligence artificielle (Dojo, Tesla Bot), ont quant à eux suscité un regain d'intérêt spéculatif. Ces événements maintiennent l'entreprise au cœur de l'attention médiatique, mais alimentent également un comportement de noise trading, souvent déconnecté des fondamentaux.

Enfin, la communication directe et parfois imprévisible d'Elon Musk constitue un facteur de volatilité en soi. Certains de ses tweets ont eu un impact immédiat et mesurable sur le cours de l'action, comme celui du 1er mai 2020 affirmant que le prix de l'action Tesla était « trop élevé », provoquant une chute de plus de 10%. L'annonce de son intention de racheter Twitter en 2022 a également suscité des inquiétudes quant à sa capacité à se consacrer pleinement à la gestion de Tesla, entraînant une baisse prolongée du titre. Ces épisodes illustrent l'importance des facteurs comportementaux et psychologiques dans la dynamique de valorisation de Tesla, rendant pertinente l'utilisation de modèles économétriques adaptés tels que les modèles GARCH pour analyser et modéliser sa volatilité.

1.5 Évolution du cours boursier



FIGURE 1 – Évolution du cours boursier

Le cours boursier de Tesla, tel qu'illustré dans le graphique, reflète une série de fluctuations marquées par des événements internes et externes qui ont influencé la perception et la valorisation de l'entreprise.

D'octobre 2019 à début 2021, le cours de l'action a connu une ascension fulgurante, passant d'une phase de stabilité relative à une croissance exponentielle. Cette période a été marquée par des annonces stratégiques et des décisions financières qui ont renforcé la confiance des investisseurs. L'inclusion dans le SP500 et les commandes massives de véhicules ont eu un impact majeur, démontrant la capacité de Tesla à attirer à la fois des investisseurs institutionnels et des clients commerciaux de grande envergure.

Cependant, cette trajectoire ascendante n'a pas été linéaire. Des événements comme le tweet d'Elon Musk ont introduit des perturbations surprenantes. Ce simple tweet a provoqué une baisse temporaire du cours de l'action, soulignant la sensibilité extrême de Tesla aux déclarations publiques de ses dirigeants. Ces incidents montrent que les actions de Tesla sont particulièrement vulnérables aux perturbations imprévues, ce qui peut à la fois stimuler et freiner la dynamique boursière.

La croissance en Chine et les records de livraisons ont été des facteurs positifs constants, soulignant la capacité de Tesla à exécuter sur le plan opérationnel. Toutefois, les incertitudes politiques et les résultats financiers variables ont ajouté de la complexité, rendant le cours de l'action sujet à des fluctuations rapides.

En 2025, le cours de l'action a connu une volatilité accrue en raison des annonces politiques (Trump tarifs) et des résultats financiers décevants. Les déclarations politiques et les performances économiques ont introduit des incertitudes supplémentaires, affectant la confiance des investisseurs. Ces fluctuations montrent que Tesla reste vulnérable aux influences externes, malgré ses succès opérationnels.

L'analyse du cours boursier de Tesla met donc en lumière une entreprise dont la valorisation est profondément influencée par un mélange de succès opérationnels, de décisions stratégiques et de facteurs externes imprévisibles. Tesla devra alors gérer ces nombreux défis et surprises pour rester le leader dans l'industrie des véhicules électriques.

2. Enjeux écologiques et innovation

2.1 Tesla et la transition énergétique mondiale

Tesla est souvent considérée comme le fer de lance de la transition énergétique mondiale, notamment grâce à ses efforts pour démocratiser les véhicules électriques (VE) et réduire les émissions de gaz à effet de serre. Grâce à une stratégie d'innovation continue, l'entreprise a su s'imposer comme un acteur incontournable dans le secteur des véhicules électriques. Mais son action ne se limite pas à la construction automobile. Tesla développe également des solutions énergétiques intégrées, notamment dans le domaine des panneaux solaires et du stockage d'énergie, avec l'ambition d'accélérer l'accès mondial à une énergie propre et renouvelable.

Dans cette optique, l'entreprise a mis en œuvre une série d'initiatives alignées avec sa mission d'accélérer la transition mondiale vers une énergie durable. Elle a ainsi popularisé les véhicules électriques à travers des modèles emblématiques tels que la Model S, la Model 3, la Model X et la Model Y, combinant haute performance, autonomie étendue et réduction significative des émissions de CO₂. Parallèlement, Tesla a conçu des solutions solaires accessibles aux particuliers, notamment les panneaux solaires traditionnels et les toitures solaires, souvent accompagnés de Powerwalls, ces batteries domestiques permettant de stocker l'énergie solaire pour une consommation différée. À une échelle plus large, des solutions comme les Powerpacks et les Megapacks ont été développées pour répondre aux besoins industriels et stabiliser les réseaux électriques.

En complément, Tesla a déployé un réseau mondial de superchargeurs, facilitant la recharge rapide des véhicules électriques et éliminant ainsi l'un des freins majeurs à leur adoption massive. En rassemblant ces technologies dans un écosystème intégré, Tesla entend réduire la dépendance aux énergies fossiles, tout en apportant une réponse concrète aux défis environnementaux mondiaux. L'entreprise poursuit ses efforts d'innovation pour rester à l'avant-garde de cette transformation énergétique globale.

2.2 Technologies propres (Gigafactory, batteries, solaire)

L'engagement de Tesla pour un avenir durable se traduit aussi par ses investissements massifs dans les technologies propres. À travers le développement de ses Gigafactories, l'entreprise a conçu des infrastructures de production à grande échelle destinées à répondre à la demande croissante en batteries lithium-ion et en modules solaires. Ces installations, situées notamment au Nevada, à Shanghai, à Berlin et au Texas, sont conçues pour fonctionner avec des énergies renouvelables et intègrent des systèmes de recyclage, contribuant ainsi à la réduction de leur empreinte carbone.

La production de batteries représente un axe central de cette stratégie. Tesla développe des cellules lithium-ion pour ses véhicules ainsi que pour ses solutions de stockage d'énergie stationnaire. Des avancées notables ont été réalisées avec les cellules 4680, qui offrent une densité énergétique accrue, une autonomie prolongée et une durée de vie améliorée. Ces innovations techniques visent à réduire le coût de production tout en renforçant la performance des véhicules électriques.

Par ailleurs, l'énergie solaire occupe une place croissante dans les activités de Tesla. La Gigafactory 2, basée à Buffalo dans l'État de New York, est spécialisée dans la fabrication de panneaux solaires et de produits connexes. Elle joue un rôle clé dans la promotion de l'autonomie énergétique des ménages et des entreprises, tout en favorisant l'extension de l'énergie solaire à l'échelle industrielle. À travers l'intégration verticale de ces différentes branches, Tesla ambitionne de bâtir un avenir énergétique fondé sur des ressources renouvelables, accessible au plus grand nombre.

2.3 Impacts environnementaux (production, recyclage, lithium)

Malgré ses ambitions environnementales, Tesla est également confrontée aux défis écologiques associés à la production de véhicules électriques et de batteries. L'un des enjeux majeurs concerne l'extraction de matières premières critiques telles que le lithium, le cobalt ou le nickel. Ces activités ont un impact environnemental et social important, notamment en termes de consommation de ressources, de pollution locale et de conditions de travail. Consciente de ces enjeux, l'entreprise cherche à renforcer la traçabilité de ses chaînes d'approvisionnement et à collaborer avec des fournisseurs respectueux des normes environnementales et sociales.

Le recyclage constitue un autre axe essentiel de la stratégie environnementale de Tesla. Le traitement des batteries usagées est une tâche complexe, nécessitant des technologies avancées et une consommation énergétique non négligeable. Pour y répondre, des systèmes de recyclage ont été installés au sein des Gigafactories, afin de récupérer les matériaux précieux et de réduire la quantité de déchets générés. L'objectif est de mettre en place une boucle circulaire permettant de réutiliser les composants des batteries en fin de vie, ce qui contribuerait à limiter la dépendance aux ressources primaires.

Enfin, les émissions de gaz à effet de serre liées à la production restent un point de vigilance, notamment durant la phase de fabrication des batteries, particulièrement énergivore. Tesla s'efforce de réduire ces émissions en alimentant ses usines avec des sources renouvelables et en optimisant ses procédés industriels. À travers ces efforts, l'entreprise entend concilier innovation technologique et responsabilité environnementale, tout en consolidant son rôle de leader dans la mobilité électrique durable.

2.4 Benchmark : Rivian, BYD, Nio

Rivian : Connu pour ses véhicules électriques robustes et ses innovations en matière de durabilité, Rivian se distingue par son approche axée sur l'aventure et l'utilisation de matériaux recyclés. L'entreprise a lancé des modèles comme le R1T, un pick-up électrique, et le R1S, un SUV électrique, qui sont conçus pour offrir des performances tout-terrain exceptionnelles tout en réduisant les émissions de gaz à effet de serre. Cependant, Rivian fait face à des défis financiers et doit encore prouver sa rentabilité à long terme. L'entreprise a connu des retards de production et des problèmes de chaîne d'approvisionnement qui ont affecté ses marges bénéficiaires. Malgré ces défis, Rivian continue d'innover et de se positionner comme un acteur clé dans le secteur des véhicules électriques.

BYD : Le géant chinois BYD est un acteur majeur dans le secteur des véhicules électriques, avec une intégration verticale impressionnante qui lui permet de contrôler la production de composants clés comme les batteries. BYD est particulièrement compétitif en termes de prix, notamment dans les marchés non occidentaux, où il sous-enchère souvent Tesla. L'entreprise a diversifié ses activités pour inclure la production de batteries, de panneaux solaires et d'autres technologies propres. BYD a également investi massivement dans la recherche et le développement pour améliorer l'efficacité et la durabilité de ses produits. En 2023, BYD est devenu le plus grand fabricant de véhicules électriques au monde, dépassant Tesla en termes de ventes. L'entreprise continue d'étendre sa présence mondiale et de renforcer sa position de leader dans le secteur des véhicules électriques.

Nio : Nio se démarque par ses innovations technologiques, telles que le système de remplacement de batteries, et son positionnement premium sur le marché chinois. L'entreprise propose des modèles comme le ES8, le ES6 et le EC6, qui sont conçus pour offrir des performances exception-

nelles et une expérience utilisateur haut de gamme. Nio a également développé des technologies avancées comme le pilote automatique et le service de remplacement de batteries, qui permettent aux conducteurs de remplacer rapidement les batteries de leurs véhicules. Cependant, Nio doit encore atteindre la rentabilité et fait face à une concurrence féroce dans un marché en pleine expansion. L'entreprise a connu des pertes financières importantes et doit continuer à innover pour maintenir sa position sur le marché.

Ces entreprises illustrent différentes approches de la transition énergétique et de l'innovation dans le secteur des véhicules électriques, chacune avec ses forces et ses défis spécifiques. Tesla, Rivian, BYD et Nio jouent tous un rôle crucial dans la promotion de la mobilité durable et la réduction des émissions de gaz à effet de serre. Leur succès dépendra de leur capacité à innover, à surmonter les défis financiers et à répondre aux attentes des consommateurs en matière de durabilité et de performance.

3. Contexte Macroéconomique et Géopolitique

3.1 Taux d'intérêt, Inflation, Pétrole

Les taux d'intérêt, l'inflation et les prix du pétrole sont des facteurs macroéconomiques essentiels qui influencent la performance des actions technologiques, y compris celles de Tesla. Ces variables économiques créent un environnement complexe dans lequel les entreprises doivent naviguer pour maintenir leur compétitivité et leur croissance.

Les taux d'intérêt jouent un rôle crucial dans la valorisation des actions. Lorsque les taux d'intérêt augmentent, les obligations deviennent plus attractives pour les investisseurs, ce qui peut entraîner une baisse des valorisations des actions. Les entreprises technologiques, qui dépendent fortement des flux de trésorerie futurs, sont particulièrement sensibles à ces fluctuations. La hausse rapide des taux d'intérêt pour contenir l'inflation a accru les risques pour les intermédiaires financiers, affectant ainsi la stabilité du système financier. Les entreprises doivent donc ajuster leurs stratégies financières pour faire face à ces nouvelles conditions de marché. Par exemple, une augmentation des taux d'intérêt peut rendre le financement de nouveaux projets ou l'expansion plus coûteux, ce qui peut limiter les capacités d'investissement de Tesla dans des domaines clés comme la recherche et développement ou l'expansion de ses infrastructures de production.

L'inflation, quant à elle, augmente les coûts des matières premières et des composants, ce qui peut réduire les marges bénéficiaires des entreprises technologiques. Par exemple, Tesla doit faire face à des coûts plus élevés pour l'acier et d'autres matériaux, ce qui peut affecter sa rentabilité. Les entreprises capables d'ajuster rapidement leurs prix, comme Tesla, peuvent mieux résister à l'inflation. Cependant, celles qui ne peuvent pas répercuter ces coûts supplémentaires sur les consommateurs verront leurs marges diminuer. L'inflation peut également influencer le pouvoir d'achat des consommateurs, ce qui peut affecter la demande pour les produits technologiques. Une inflation élevée peut réduire la capacité des consommateurs à acheter des véhicules électriques, ce qui peut ralentir les ventes de Tesla. De plus, l'inflation peut également affecter les coûts de la main-d'œuvre, ce qui peut augmenter les coûts de production pour Tesla.

Les fluctuations des prix du pétrole influencent également la demande pour les véhicules électriques. Des prix élevés du pétrole peuvent rendre les véhicules électriques plus attractifs, augmentant ainsi la demande pour les produits de Tesla. Cependant, les prix élevés du pétrole peuvent également augmenter les coûts de production, notamment pour les composants en plastique et les matériaux dérivés du pétrole utilisés dans la fabrication des véhicules. Les entreprises doivent donc trouver un équilibre entre la gestion des coûts de production et la satisfaction de la demande des consommateurs. Par exemple, une hausse des prix du pétrole peut augmenter les coûts de transport des matières premières et des composants, ce qui peut affecter les marges bénéficiaires de Tesla. De plus, les prix élevés du pétrole peuvent également inciter les consommateurs à rechercher des alternatives plus économiques, ce qui peut stimuler la demande pour les véhicules électriques de Tesla.

3.2 Subventions et Politique Fiscale Américaine

L'Inflation Reduction Act (IRA) de 2022 a eu un impact significatif sur Tesla. Cette loi offre des crédits d'impôt pour les véhicules électriques, ce qui peut stimuler les ventes de Tesla. Cependant, les critères d'éligibilité ont changé, et certains modèles Tesla ont perdu leur éligibilité, ce qui pourrait affecter les ventes. Par exemple, à partir du 31 décembre 2023, les modèles Tesla Model 3 Rear-Wheel Drive et Long Range ont perdu leur éligibilité aux crédits d'impôt, ce qui

représente un coup dur pour Tesla et pourrait affecter sa compétitivité sur le marché. Cette perte d'éligibilité peut rendre les véhicules Tesla moins attractifs pour les consommateurs par rapport à d'autres véhicules électriques qui bénéficient encore des crédits d'impôt.

L'IRA encourage également la production locale aux États-Unis, ce qui pourrait bénéficier à Tesla à long terme. Cependant, cette exigence nécessite des ajustements dans la chaîne d'approvisionnement de Tesla. L'entreprise doit investir dans des capacités de production locales pour répondre aux nouvelles réglementations et maintenir son éligibilité aux crédits d'impôt. Ces investissements peuvent être coûteux à court terme, mais ils peuvent offrir des avantages concurrentiels à long terme. Par exemple, Tesla peut bénéficier de coûts de transport réduits et d'une plus grande flexibilité dans la gestion de sa chaîne d'approvisionnement en produisant localement. De plus, la production locale peut également renforcer la perception de la marque Tesla en tant qu'entreprise engagée dans la création d'emplois et le développement économique aux États-Unis.

3.3 Conflits Commerciaux

Les conflits commerciaux entre les États-Unis, la Chine et l'Europe ont également des répercussions sur Tesla. Les tensions commerciales entre les États-Unis et la Chine ont conduit à des droits de douane élevés, augmentant les coûts pour Tesla et réduisant ses marges bénéficiaires en Chine. Malgré ces défis, la Chine reste un marché clé pour Tesla en raison de sa taille et de son potentiel de croissance. Tesla a construit une Gigafactory à Shanghai pour contourner les barrières commerciales et accéder directement au marché chinois. Cette stratégie permet à Tesla de réduire les coûts liés aux droits de douane et de renforcer sa position sur le marché chinois. Cependant, la construction et l'exploitation de la Gigafactory à Shanghai ont également présenté des défis, notamment en termes de coûts initiaux élevés et de complexité opérationnelle.

L'Europe a mis en place des subventions pour les véhicules électriques, mais les réglementations strictes et les droits de douane peuvent compliquer les opérations de Tesla sur le continent. La concurrence des constructeurs automobiles européens, soutenus par des subventions locales, peut également affecter la part de marché de Tesla en Europe. Tesla doit donc adapter ses stratégies commerciales pour répondre aux exigences réglementaires et concurrentielles du marché européen. Par exemple, Tesla peut être confrontée à des exigences strictes en matière d'émissions et de normes de sécurité en Europe, ce qui peut nécessiter des investissements supplémentaires dans la recherche et développement pour se conformer à ces réglementations. De plus, les droits de douane et les barrières commerciales peuvent augmenter les coûts d'importation des véhicules Tesla en Europe, ce qui peut affecter leur compétitivité par rapport aux véhicules électriques produits localement.

Tesla doit donc naviguer dans un environnement complexe marqué par des défis macroéconomiques et géopolitiques. La gestion efficace de ces variables est cruciale pour maintenir sa compétitivité et sa croissance à long terme. Tesla doit continuer à innover et à adapter ses stratégies pour répondre aux fluctuations du marché et aux exigences réglementaires. En investissant dans des capacités de production locales et en diversifiant ses sources d'approvisionnement, Tesla peut renforcer sa position sur les marchés mondiaux et atténuer les risques liés aux conflits commerciaux et aux fluctuations économiques. De plus, Tesla doit rester attentive aux évolutions des politiques de subventions et aux changements dans les préférences des consommateurs pour maintenir sa compétitivité sur le marché des véhicules électriques.

4. Analyse financière de Tesla Inc.

4.1 Répartition du CA

Par secteur d'activité :




FIGURE 2 – Répartition du chiffre d'affaires par secteur d'activité

L'analyse de la répartition du chiffre d'affaires de Tesla révèle une très forte concentration de son activité autour de la vente de véhicules. En effet, cette branche représente à elle seule 74% des revenus totaux de l'entreprise. Cela confirme que, malgré les nombreuses ambitions de diversification portées par Elon Musk – notamment dans les domaines de l'énergie, de la technologie ou encore des services financiers – Tesla reste avant tout un constructeur automobile. Les autres activités de l'entreprise, bien que présentes, pèsent nettement moins dans la balance. Les prestations de services représentent 11% du chiffre d'affaires, tandis que les ventes de systèmes de production (qui incluent vraisemblablement les panneaux solaires et les batteries) en représentent 10%. Le crédit automobile, une activité en plein essor avec les financements proposés pour les achats de véhicules, ne pèse que 3%, et la location de véhicules, 2%. Ces données montrent que Tesla a entamé une diversification, mais celle-ci reste encore secondaire dans son modèle économique.

Par zone géographique :




FIGURE 3 – Répartition géographique du chiffre d'affaires

Sur le plan géographique, la répartition du chiffre d'affaires met en évidence l'importance stratégique du marché américain pour Tesla. Environ la moitié des revenus de l'entreprise provient des États-Unis, ce qui montre une forte dépendance au marché domestique. Vient ensuite la Chine, qui représente environ un quart du chiffre d'affaires. Ce pays est crucial pour Tesla, notamment en raison de son usine de Shanghai, qui permet de produire à grande échelle pour le marché asiatique, tout en bénéficiant d'un coût de production réduit. Enfin, les autres zones géographiques – principalement l'Europe, le Moyen-Orient et d'autres marchés émergents – constituent un peu moins d'un tiers du chiffre d'affaires. Cette répartition illustre la stratégie de Tesla d'ancrer solidement ses positions aux États-Unis et en Chine, tout en continuant à se développer à l'international.

4.2 Données financières

Indicateur	2024	2023	2022
Chiffre d'affaires	97.7 Mds \$	96.8 Mds \$	81.5 Mds \$
Capitalisation boursière	1300 Mds \$	772 Mds \$	435 Mds \$
PER	197.96	57.65	34.00
EBITDA	12.44 Mds \$	13.56 Mds \$	17.40 Mds \$
ROE (%)	9.71	23.63	27.67
ROA (%)	5.86	14.04	15.29
Bêta	2.58	—	—
Marge nette (%)	7.30	15.50	15.45
Marge opérationnelle (%)	7.24	9.18	16.77

TABLE 1 – Principaux indicateurs financiers de Tesla Inc. (2022–2024)

Les données financières de l'entreprise sur la période 2022–2024 permettent de dresser un bilan contrasté, marqué par une croissance du chiffre d'affaires et une envolée de la valorisation boursière, mais aussi par une dégradation des indicateurs de rentabilité. Ce déséquilibre soulève un risque de surévaluation significatif que cette analyse cherche à éclairer.

Entre 2022 et 2024, l'entreprise a enregistré une progression continue de son chiffre d'affaires, passant de 81,5 à 97,7 milliards de dollars. Cette performance témoigne d'un bon positionnement commercial et d'une expansion maîtrisée. Toutefois, cette croissance des revenus ne s'est pas accompagnée d'une amélioration des résultats financiers : l'EBITDA, le ROE et le ROA affichent tous une tendance baissière sur la période. Par exemple, le ROE chute de 27,67% en 2022 à seulement 9,71% en 2024, signalant une rentabilité du capital nettement affaiblie.

La capitalisation boursière de l'entreprise est passée de 435 milliards de dollars en 2022 à 772 milliards en 2023, pour atteindre 804 milliards en 2024. Cette augmentation, bien que favorablement interprétée par les marchés, s'accompagne d'un envol du ratio Price Earning (PER) : 34,00 en 2022, 57,65 en 2023, puis un niveau extrêmement élevé de 197,96 en 2024. Un tel PER, très au-delà des standards du marché, constitue un signal d'alerte majeur. En effet, un PER aussi élevé signifie que les investisseurs paient près de 198 dollars pour chaque dollar de bénéfice généré, ce qui n'est justifiable que si l'entreprise est en mesure de générer une croissance très rapide et durable de ses bénéfices futurs. Or, les données sur la rentabilité montrent au contraire une détérioration continue. Ce décalage entre valorisation et fondamentaux traduit une forme de dissonance financière, symptomatique d'une surévaluation du titre. Risque de correction boursière accru

Le bêta de 2,58 (valeur relevée en 2025) renforce ce diagnostic : il traduit une volatilité plus que doublée par rapport au marché. Dans un tel contexte, tout ajustement des anticipations de croissance ou de rentabilité pourrait entraîner une correction rapide et violente du cours de l'action. Le PER élevé couplé à une forte volatilité rend l'action particulièrement sensible aux changements de sentiment des investisseurs et aux chocs externes.

En outre, l'entreprise présente une dynamique de croissance favorable en termes de chiffre d'affaires et une valorisation boursière croissante, traduisant l'enthousiasme du marché. Néanmoins, la dégradation des indicateurs de rentabilité interroge sur la soutenabilité de cette valorisation. Le couple risque/rendement semble s'être modifié au cours des trois dernières années, rendant la prudence nécessaire dans l'interprétation des signaux boursiers. Une diversification géographique et sectorielle accrue pourrait constituer un levier pertinent pour atténuer la volatilité et consolider une croissance durable à moyen et long terme.

5. Partie empirique – Analyse et modélisation de la volatilité

5.1 Préparation des données

5.1.1 Présentation des données

L'analyse économétrique du risque de marché de Tesla Inc. repose sur l'étude de son cours boursier journalier. Les données utilisées proviennent de la plateforme The Wall Street Journal, une source fiable et largement utilisée dans les travaux académiques comme professionnels. Nous avons extrait le cours de clôture ajusté (adjusted close), qui intègre les dividendes et ajustements liés aux splits d'actions, pour refléter fidèlement la performance de l'action.

La série couvre la période allant du 27 mars 2015 au 26 mars 2025, avec une fréquence quotidienne (données de jours ouvrés uniquement). Ce choix permet de capter à la fois les mouvements de long terme et les fluctuations de court terme nécessaires à la modélisation de la volatilité. L'échantillon comprend 2 513 observations, soit un volume suffisant pour permettre l'estimation robuste des modèles GARCH.

Un contrôle de cohérence a été effectué pour :

- Supprimer les dates manquantes (jours fériés, suspension de marché) ;
- Éliminer les doublons éventuels ;
- Vérifier la continuité temporelle de la série.

Aucune anomalie significative n'a été observée sur la série extraite. Les données sont donc considérées comme exploitables en l'état.

5.1.2 Transformation logarithmique

Avant toute estimation des rendements ou l'application de modèles économétriques tels que ARMA-GARCH, une transformation logarithmique est appliquée à la série des cours ajustés de l'action Tesla. Cette étape préliminaire est couramment utilisée en économétrie financière pour des raisons à la fois mathématiques, statistiques et économiques.

Tout d'abord, le logarithme permet de stabiliser la variance relative de la série. En effet, les séries de prix financiers, notamment celles d'actions à forte croissance comme Tesla, ont souvent une structure exponentielle, avec des valeurs récentes très élevées qui peuvent dominer visuellement et statistiquement la série. Cela rend les comparaisons temporelles peu pertinentes. En appliquant le logarithme, on réduit l'écart d'échelle et on homogénéise la série, rendant les variations plus comparables dans le temps.




FIGURE 4 – Évolution du cours de l'action Tesla en logarithme (2015–2025)

5.1.3 Corrélogramme du logarithme de Tesla

L'examen du corrélogramme de la série logarithmique des prix ajustés de l'action Tesla met en lumière une autocorrélation persistante sur de nombreux décalages. Le premier retard présente un coefficient d'autocorrélation partielle (PAC) très élevé, tandis que les coefficients d'autocorrélation (AC) diminuent très lentement au fil des retards. Ce comportement est typique d'une série présentant une tendance de type stochastique.

Une tendance stochastique désigne une dynamique dont l'évolution dépend d'un processus aléatoire, rendant sa trajectoire difficilement prévisible. Contrairement à une tendance déterministe, elle implique que les propriétés statistiques de la série, telles que la moyenne ou la variance varient dans le temps, ce qui constitue une source directe de non-stationnarité.

Afin de valider rigoureusement la stationnarité ou la non-stationnarité de la série, nous appliquons par la suite trois tests classiques et complémentaires :

- le test ADF (Augmented Dickey-Fuller).
- le test PP (Phillips-Perron).
- le test KPSS. (Kwiatkowski-Phillips-Schmidt-Shin)

Ces tests, appliqués de manière conjointe, permettent de renforcer la robustesse du diagnostic et de guider le choix des transformations nécessaires avant toute modélisation.

Date: 04/07/25 Time: 13:05
Sample: 3/27/2015 3/26/2025
Included observations: 2513




FIGURE 5 – Corrélogramme de LTESLA

5.2 Analyse de la stationnarité

5.2.1 Test de Dickey-Fuller augmenté

Le test de Dickey-Fuller augmenté (ADF) est couramment utilisé en économétrie pour évaluer si une série temporelle est stationnaire ou non. Ce test permet de déterminer si une racine unitaire est présente dans la série, ce qui indiquerait une non-stationnarité.

Dans ce cadre, l'évolution de la série est analysée afin de déterminer si les chocs qui l'affectent ont des effets transitoires (stationnarité) ou permanents (non-stationnarité). Le test a été introduit comme une extension du test de Dickey-Fuller initial, dans le but de tenir compte de l'autocorrélation dans les erreurs à travers l'ajout de retards supplémentaires.

Dans le cadre de cette étude, le test ADF est appliqué à la série, correspondant au logarithme du prix ajusté de l'action Tesla. Compte tenu des éléments observés dans le corrélogramme (persistances des autocorrélations, tendance apparente), les trois versions du test sont examinées afin de choisir la spécification la plus appropriée.

Les résultats permettent d'évaluer formellement la présence ou non d'une racine unitaire dans la série et de justifier, si nécessaire, son passage en différence logarithmique, c'est-à-dire le calcul des rendements utilisés dans la modélisation de la volatilité.

Le modèle sur lequel repose le test ADF peut être représenté de la manière suivante :

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^p \delta_i \Delta Y_{t-i} + \varepsilon_t \quad (1)$$

Dans cette équation :

- Y_t désigne la série étudiée (ici le logarithme du cours de l'action Tesla) ;
- ΔY_t correspond à la première différence ($Y_t - Y_{t-1}$) ;
- α constante représentant un terme fixe.
- βt terme de tendance déterministe (optionnel selon la version du test) ;
- p correspond au nombre de retards inclus pour corriger l'autocorrélation ;
- ε_t désigne le terme d'erreur.

Le test ADF est fondé sur la confrontation entre deux hypothèses :

Hypothèse nulle (\mathcal{H}_0) : une racine unitaire est présente ($\gamma = 0$) \rightarrow la série est non stationnaire. (ADF > Valeur critique)

Hypothèse alternative (\mathcal{H}_1) : aucune racine unitaire n'est présente ($\gamma < 0$) \rightarrow la série est stationnaire. (ADF < Valeur critique)

Ainsi, la non-stationnarité est postulée par défaut, et c'est cette hypothèse qui est soumise à test. La statistique de test associée à γ est comparée à des valeurs critiques spécifiques fournies par **MacKinnon (1996)**, distinctes de celles des tests- t classiques.

T	Constante (2)	Constante (3)	Tendance (3)
100	2.54	3.11	2.79
∞	2.52	3.08	2.78

TABLE 2 – Valeur critique de ADF 5%

Le test ADF peut être formulé sous trois spécifications différentes :

- Modèle 1 : sans constante, ni tendance
- Modèle 2 : avec constante
- Modèle 3 : avec constante et tendance linéaire

Modèle	Statistique ADF	Valeur critique du test	Conclusion
1	1.188015	-1.940951	Non stationnaire
2	-0.767970	-2.862499	Non stationnaire
3	-1.781638	-3.411610	Non stationnaire

TABLE 3 – Résultat du test ADF

Les résultats obtenus pour les trois spécifications du test ADF (sans constante, avec constante, et avec constante et tendance) indiquent que la statistique de test est systématiquement supérieure aux valeurs critiques aux niveaux usuels de signification. Ainsi, l'hypothèse nulle de présence d'une racine unitaire ne peut être rejetée, ce qui conduit à conclure que la série est non stationnaire, quelle que soit la forme du modèle retenu.

5.2.2 Test de Phillips-Perron

Le test de Phillips-Perron (PP), développé par Phillips et Perron en 1988, constitue une alternative robuste au test de Dickey-Fuller augmenté. Comme ce dernier, il est utilisé pour déterminer si une série temporelle est stationnaire ou non, en testant la présence d'une racine unitaire.

L'intérêt principal du test PP réside dans sa formulation non paramétrique : contrairement au test ADF, aucun terme de retard supplémentaire n'est introduit dans le modèle. L'autocorrélation des résidus est corrigée directement au niveau de la variance des erreurs, à l'aide de méthodes d'estimation robustes à l'hétéroscédasticité et à l'autocorrélation de forme inconnue.

Le modèle sur lequel repose le test PP peut être représenté de la manière suivante :

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \varepsilon_t \quad (2)$$

Avec :

- ΔY_t : correspond à la première différence ($Y_t - Y_{t-1}$) ;
- α : constante représentant un terme fixe. ;
- βt : terme de tendance déterministe (optionnel selon la version du test) ;
- γY_{t-1} : terme contenant la racine unitaire ; c'est le paramètre clé du test (la stationnarité est rejetée si $\gamma = 0$) ;
- ε_t : désigne le terme d'erreur ;

Les hypothèses sont les mêmes que pour le test ADF :

- \mathcal{H}_0 : la série possède une racine unitaire ($\gamma = 0$) \rightarrow non stationnarité
- \mathcal{H}_1 : la série est stationnaire ($\gamma < 0$)

La présence d'une racine unitaire implique que les chocs subis par la série ont un effet permanent, et que sa moyenne, sa variance et ses autocorrélations ne sont pas constantes dans le temps.

Dans le cadre de ce travail, le test de Phillips-Perron a été appliqué à la série, c'est-à-dire au logarithme du prix ajusté de l'action Tesla. Les trois formes du test ont été considérées.

Le test PP comme le test ADF eut être formulé sous trois spécifications différentes :

- **Modèle 1** : sans constante, ni tendance
- **Modèle 2** : avec constante
- **Modèle 3** : avec constante et tendance linéaire

Modèle	Statistique PP	Valeur critique du test	Conclusion
1	1.266676	-1.940950	Non stationnaire
2	-0.854636	-2.862490	Non stationnaire
3	-1.697637	-3.411597	Non stationnaire

TABLE 4 – Résultat du test PP

Dans chaque cas, la statistique de test PP est apparue supérieure aux valeurs critiques, ce qui empêche le rejet de l'hypothèse nulle. Il en résulte que la série logarithmique de prix est non stationnaire, confirmant ainsi les conclusions déjà obtenues via le test ADF.

5.2.3 Test de Kwiatkowski–Phillips–Schmidt–Shin

Le test de Kwiatkowski, Phillips, Schmidt et Shin (KPSS), proposé en 1992, est utilisé pour vérifier la stationnarité d'une série temporelle, mais se distingue fondamentalement des tests ADF et PP par l'inversion des hypothèses statistiques.

Alors que l'ADF et le PP testent la présence d'une racine unitaire (non stationnarité), le test KPSS postule la stationnarité comme hypothèse nulle. De ce fait, il est souvent utilisé en complément des deux premiers pour obtenir une analyse plus robuste.

La statistique de test KPSS est définie comme suit :

$$\text{KPSS} = \frac{1}{T^2} \sum_{t=1}^T S_t^2 / \hat{\sigma}^2 \quad (3)$$

Où :

- T : nombre total d'observations de la série.
- S_t : somme cumulée des résidus estimés du modèle de régression sous \mathcal{H}_0 , c'est-à-dire :

$$S_t = \sum_{i=1}^t \hat{\varepsilon}_i$$

- $\hat{\varepsilon}_i$: résidu de la régression de Y_t sur une constante (ou une constante et une tendance, selon la spécification).
- $\hat{\sigma}^2$: estimation de la variance du bruit blanc ε_t , généralement obtenue à l'aide d'un estimateur de type Newey-West, robuste à l'autocorrélation.

Contrairement aux autres tests, les hypothèses sont les suivantes :

- \mathcal{H}_0 (hypothèse nulle) : la série est stationnaire (autour d'une moyenne ou d'une tendance) ;
- \mathcal{H}_1 (hypothèse alternative) : la série est non stationnaire (présence d'une racine unitaire).

Le test produit une statistique KPSS, qui doit être comparée à des valeurs critiques non standardisées, fournies par **Kwiatkowski (1992)** pour différents niveaux de signification.

Si la statistique KPSS est supérieure à la valeur critique $\Rightarrow \mathcal{H}_0$ est rejetée : la série est non stationnaire.

Si la statistique KPSS est inférieure ou proche de la valeur critique $\Rightarrow \mathcal{H}_0$ n'est pas rejetée : la série est considérée comme stationnaire.

Comme pour les tests ADF et PP, le test peut être effectué avec ou sans tendance déterministe. Le test KPSS peut être formulé sous deux spécifications différentes :

- Modèle 1 : avec constante et tendance linéaire
- Modèle 2 : avec constante

Dans les deux cas, la statistique de test obtenue dépasse les valeurs critiques au seuil de 5%, ce qui conduit à rejeter l'hypothèse nulle de stationnarité. Ces résultats confirment donc que la série présente une composante non stationnaire, en accord avec les conclusions issues des tests ADF et PP.

Modèle	Statistique KPSS	Valeur critique du test	Conclusion
1	0.543599	0.146000	Non stationnaire
2	5.452396	0.463000	Non stationnaire

TABLE 5 – Résultat du test KPSS

Les résultats croisés des tests ADF, PP et KPSS convergent vers la même conclusion : la série $\ln(P_t)$ n'est pas stationnaire, quelle que soit la spécification retenue. Une transformation en rendements (différences logarithmiques) s'avère donc nécessaire avant d'envisager toute modélisation ARMA ou GARCH.

Test	Conclusion
ADF	Non stationnaire
PP	Non stationnaire
KPSS	Non stationnaire

TABLE 6 – Résultat des tests de stationnarité

5.3 Stationnarisation de la série

5.3.1 Passage à la différence première

Les tests de racine unitaire appliqués à la série logarithmique du prix de l'action Tesla (ADF, PP, KPSS) ont conduit à conclure que celle-ci est non stationnaire. Dans ce contexte, une stationnarisation est nécessaire avant toute modélisation économétrique.

La méthode la plus courante et la plus rigoureusement justifiée consiste à appliquer une différenciation de premier ordre, c'est-à-dire à calculer la différence première de la série logarithmique. Ce traitement permet d'éliminer la tendance stochastique présente dans les données.

Définition mathématique

Soit $Y_t = \ln(P_t)$, le logarithme népérien du prix ajusté de l'action Tesla.

La différence première est définie comme :

$$\Delta Y_t = Y_t - Y_{t-1} = \ln(P_t) - \ln(P_{t-1}) = \ln\left(\frac{P_t}{P_{t-1}}\right) \quad (4)$$

Cette expression correspond au *rendement logarithmique* entre deux dates successives. Il s'agit d'une transformation standard dans l'analyse des séries financières.




FIGURE 6 – Rendements logarithmique stationnarisés de Tesla

Par cette transformation en différence première logarithmique, une série de rendements journaliers de l'action Tesla a été obtenue. Cette série sera utilisée dans la suite de l'analyse pour réaliser une description statistique, tester sa stationnarité, et construire des modèles économétriques destinés à modéliser sa volatilité et estimer la Value at Risk (VaR).

Ce graphique permet d'observer visuellement que la moyenne des rendements a été stabilisée autour de zéro, ce qui constitue une propriété attendue des séries de rendements après transformation. On remarque également une forte volatilité autour de l'année 2020, en lien avec la crise sanitaire liée à la Covid-19. Cette période de turbulence s'accompagne d'un phénomène bien connu en finance : un cluster de volatilité, caractérisé par une succession de fortes variations, souvent observées en période de stress ou d'incertitude sur les marchés. Par ailleurs, le graphique met en évidence une chute particulièrement marquée du rendement sur une journée, représentant la plus forte variation négative de la série. Ce type d'événement extrême est qualifié de black swan, en référence à un choc imprévisible ayant un impact significatif sur les marchés financiers.

5.3.2 Analyse descriptive des rendements stationnarisés

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
DLTESLA	7.246638	-0.0868594	0.036458	1890.711

TABLE 7 – Statistique descriptive des rendements stationnarisés

La série de rendements obtenue après transformation du logarithme du prix a été soumise à une analyse statistique descriptive. Les résultats sont présentés dans le tableau ci-dessous, portant sur les 2512 observations quotidiennes.

Tendance centrale et dispersion

La moyenne des rendements est de 0,001232, elle se rapproche bien de zéro comme prévue par

la stationnarisation. La médiane est très proche de la moyenne (0,001258), ce qui suggère une distribution relativement symétrique malgré la présence de valeurs extrêmes. Le maximum est de 0,198, soit un gain de près de +19,8% en une journée, tandis que le minimum atteint -23,65%, illustrant une forte amplitude de variation journalière, caractéristique d'un actif très volatil. L'écart-type de la série est de 0,0365, ce qui confirme cette volatilité élevée, fréquente chez les actions de croissance comme Tesla.

Asymétrie et aplatissement de la distribution

L'asymétrie (skewness) est légèrement négative (-0,0869), indiquant une distribution légèrement biaisée à gauche. Cela signifie que les rendements négatifs extrêmes sont plus fréquents ou plus intenses que les positifs. Le kurtosis est de 7,25, bien supérieure à 3 (valeur de du kurtosis d'une loi normale). Cela indique une distribution leptokurtique, c'est-à-dire avec des queues épaisses : les valeurs extrêmes (pertes ou gains) sont plus fréquentes que dans une loi normale.

Ces résultats soulignent la nécessité d'utiliser des modèles capables de capturer la volatilité conditionnelle et les événements rares, comme les modèles GARCH, voire EGARCH ou GJR-GARCH, ou l'introduction de distributions alternatives (loi de Student, GED...).

Le test de Jarque-Bera affiche une statistique très élevée (1890,71) avec une probabilité associée de 0,000, ce qui permet de rejeter l'hypothèse nulle de normalité. Ce rejet confirme que les rendements ne suivent pas une loi normale, en raison du kurtosis excessive et de la légère asymétrie.

Cette analyse statistique met en évidence que les rendements de l'action Tesla présentent les caractéristiques classiques d'une série financière : volatilité importante, distribution asymétrique, présence de queues épaisses, et non-normalité. Ces observations justifient l'adoption de modèles économétriques adaptés à l'analyse du risque, notamment ceux capables de modéliser l'hétéroscédasticité conditionnelle (GARCH) et d'intégrer des distributions alternatives à la normale pour l'estimation de la VaR.

5.3.3 Vérification de la stationnarité

Après transformation de la série en différences premières logarithmiques, soit les rendements journaliers, une nouvelle vérification de la stationnarité a été effectuée. L'objectif est de confirmer empiriquement que la transformation a permis d'obtenir une série adaptée aux traitements économétriques de type ARMA-GARCH.

Les mêmes modèles utilisés pour détecter la présence d'une racine unitaire sont réutilisés dans cette section, à savoir les tests ADF, PP et KPSS

Modèle	Statistique	Valeur critique du test	Conclusion
ADF	-50.21419	-1.940950	Stationnaire
PP	-50.33450	-1.940950	Stationnaire
KPSS	0.098734	0.146000	Stationnaire

TABLE 8 – Résultat des tests de stationnarité 2

5.4 Estimation des modèles ARMA

Avant d'estimer la variance conditionnelle via un modèle GARCH, il convient de modéliser la composante de moyenne des rendements. Pour ce faire, des modèles ARMA(p, q) sont utilisés afin de capturer d'éventuelles dépendances temporelles dans la dynamique des rendements journaliers.

L'objectif est de sélectionner la meilleure spécification (p, q) à intégrer dans la partie de moyenne du futur modèle ARMA-GARCH, tout en assurant la stationnarité et la résidualité non auto-corrélée.

	MA 1	MA 2	MA 3	MA 4	MA 5
AR 1	-3.783390	-3.783888	-3.783500	-3.782779	-3.783142
AR 2	-3.783525	-3.788682	-3.787962	-3.787385	-3.786590
AR 3	-3.782626	-3.787589	-3.787239	-3.786202	-3.785975
AR 4	-3.782190	-3.786663	-3.785865	-3.786556	-3.788472
AR 5	-3.776587	-3.786241	-3.786174	-3.788543	-3.788312

TABLE 9 – Valeurs de la statistique AIC pour différents modèles ARMA(p,q)

Un ensemble de modèles ARMA(p, q) a été estimé afin de modéliser la dynamique des rendements de l'action Tesla. La sélection des ordres p et q a été effectuée à l'aide du critère d'information d'Akaike (AIC), qui privilégie les modèles offrant le meilleur compromis entre qualité d'ajustement et complexité, en minimisant la perte d'information.

D'après le critère d'Akaike, le modèle présentant la meilleure performance d'ajustement est un ARMA(2,2). L'ensemble des coefficients estimés dans ce modèle sont statistiquement significatifs.

Nous procédons à présent à une série de tests statistiques sur les résidus du modèle ARMA(2,2) sélectionné. Trois aspects sont examinés : l'autocorrélation, à l'aide du test de Ljung-Box, afin de vérifier que les résidus ne présentent pas de dépendance temporelle résiduelle, l'hétéroscédasticité via le test d'ARCH, pour détecter la présence éventuelle de variance conditionnelle et enfin la normalité des résidus, généralement testée à l'aide du test de Jarque-Bera.

Statistique de Ljung-Box

La statistique de test est définie comme suit :

$$Q = T(T+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{T-k} \quad (5)$$

Où :

- T : nombre d'observations ;
- m : nombre de retards (lags) retenus dans le test ;
- $\hat{\rho}_k$: autocorrélation des résidus au retard k ;

Hypothèses du test :

- H_0 : les résidus sont non autocorrélés (bruit blanc) ;
- H_1 : les résidus présentent de l'autocorrélation ;

Test ARCH LM La formule de la statistique χ^2 est donnée par :

$$\text{ARCH LM stat} = T \cdot R^2 \quad (6)$$

Où :

- R^2 est le coefficient de détermination issu de la régression des résidus au carré sur leurs propres retards ;
- T est le nombre total d'observations ;
- La statistique suit une loi du χ^2 avec q degrés de liberté (correspondant au nombre de retards inclus).

Hypothèses du test :

- H_0 : absence d'effet ARCH (résidus homoscédastiques) ;
- H_1 : présence d'effet ARCH (hétéroscédasticité conditionnelle).

Test de normalité – Jarque-Bera La statistique de Jarque-Bera est définie par la formule suivante :

$$JB = \frac{T}{6} \left(S^2 + \frac{(K - 3)^2}{4} \right) \quad (7)$$

Où :

- T : nombre total d'observations ;
- S : coefficient d'asymétrie (skewness) ;
- K : coefficient d'aplatissement (kurtosis) ;
- La statistique suit une loi du χ^2 avec 2 degrés de liberté.

Hypothèses du test :

- H_0 : les résidus suivent une loi normale ;
- H_1 : les résidus ne suivent pas une loi normale.

Les résultats des tests statistiques appliqués aux résidus du modèle ARMA(2,2) révèlent plusieurs points importants. Le test de Ljung-Box a permis de détecter une autocorrélation résiduelle significative, indiquant que la dynamique temporelle des rendements n'est pas entièrement captée par le modèle ARMA seul. Par ailleurs, le test ARCH-LM a conduit au rejet de l'hypothèse de variance constante, suggérant la présence d'hétéroscédasticité conditionnelle. Enfin, le test de Jarque-Bera a mis en évidence une non-normalité des résidus, ce qui remet en cause l'hypothèse de normalité généralement posée dans les modèles linéaires classiques.

Ces éléments confirment que la série présente une structure de volatilité conditionnelle, couplée à des dépendances résiduelles, justifiant l'estimation de modèle ARCH.

5.5 Estimation des modèles ARCH

5.5.1 Modèle GARCH

Le modèle GARCH, acronyme de Generalized Autoregressive Conditional Heteroskedasticity, a été introduit par Tim Bollerslev (1986) comme une extension du modèle ARCH (Engle, 1982). Il a pour objectif de modéliser la variance conditionnelle d'une série temporelle en fonction de ses propres valeurs passées, et des carrés des chocs précédents.

Contrairement au modèle ARCH(p), dans lequel seule la dépendance aux chocs passés est prise en compte, le modèle GARCH introduit un terme de persistance de la variance, ce qui permet de mieux représenter la dynamique de la volatilité observée sur les marchés financiers.

Le modèle GARCH est largement utilisé en économétrie financière en raison de sa capacité à capturer les caractéristiques essentielles des séries de rendements, notamment la volatilité conditionnelle et le phénomène de volatility clustering. Ce type de modèle permet de modéliser la volatilité future d'un actif, de prendre en compte les chocs persistants affectant les marchés financiers, et de calculer des mesures de risque telles que la Value at Risk (VaR). Il constitue également un outil indispensable pour intégrer l'hétéroscédasticité dans les modèles de prévision, assurant ainsi une meilleure spécification des dynamiques financières.

Dans le cadre de cette étude, un modèle GARCH(1,1) est estimé afin de modéliser la volatilité des rendements de l'action Tesla Inc., caractérisés par une forte variabilité au cours du temps. Cette étape est cruciale pour une évaluation rigoureuse du risque de marché associé à ce titre et constitue un préalable fondamental au calcul de la VaR.

Formule générale de la variance conditionnelle dans un modèle GARCH(p, q) :

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (8)$$

Détails des termes :

- σ_t^2 : variance conditionnelle au temps t , c'est la volatilité anticipée à l'instant t ;
- $\omega > 0$: constante de variance, représentant une base minimale de volatilité ;
- $\alpha_i \geq 0$: coefficients ARCH, mesurant l'impact des chocs passés (ε_{t-i}^2) ;
- $\beta_j \geq 0$: coefficients GARCH, mesurant la persistance de la volatilité passée (h_{t-j}) ;
- ε_{t-i}^2 : carrés des résidus, représentant les chocs passés sur la série ;
- σ_{t-j}^2 : valeurs passées de la variance conditionnelle.

Dans le cadre d'un modèle GARCH, la variance conditionnelle évolue dans le temps en réponse aux chocs passés (innovations sur les rendements) et à sa propre dynamique. Toutefois, en l'absence de nouveaux chocs et sous l'hypothèse de stationnarité, cette variance tend à converger vers une valeur constante. Cette valeur est appelée variance inconditionnelle, ou variance de long terme, notée σ^2 .

La variance inconditionnelle représente le niveau moyen autour duquel fluctue la variance conditionnelle au fil du temps. Elle joue un rôle fondamental dans l'analyse de la volatilité, en permettant notamment de quantifier le niveau "normal" de risque d'un actif financier, de comparer la volatilité moyenne entre différents actifs ou sur différentes périodes, et d'évaluer la contribution relative des chocs temporaires par rapport à la tendance structurelle de la volatilité.

Dans le cadre d'un modèle GARCH(1,1), la variance de long terme σ^2 est donnée par la formule suivante :

$$\sigma^2 = \frac{\omega}{1 - \alpha - \beta} \quad (9)$$

La formule de la variance de long terme dans un modèle GARCH(1,1) est valide uniquement sous la condition que $\alpha + \beta < 1$. Cette inégalité garantit que le processus est stationnaire en variance, ce qui signifie que la variance conditionnelle converge vers une valeur constante dans

le temps et que les effets des chocs passés finissent par s'estomper.

Ici le modèle GARCH(1,1) :

Modèle	Oméga	Alpha	Bêta	AIC
GARCH(1,1)	0.00000935	0.032756	0.961062	-3.916550

TABLE 10 – GARCH(1,1)

la variance de long terme est donc de $\frac{0.00000935}{1-0.032756-0.961062} = 0,00165$.

Donc :

$$\sigma^2 = 0.00165 \Rightarrow \sigma = \sqrt{0.00165} \approx 0.041$$

Cela signifie une volatilité journalière moyenne d'environ 4.1 %.

Ce niveau de volatilité est élevé, mais plausible pour une action comme Tesla.

le modèle GARCH(1,1) nous permet donc de modéliser la volatilité de l'action tesla.




FIGURE 7 – Volatilité des rendements

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
GARCH(1,1)	6.572228	-0.022664	0.999866	1334.783

TABLE 11 – Statistique descriptive des résidus du modèle GARCH(1,1)

On observe que le modèle permet de réduire légèrement les indicateurs de kurtosis et de skewness, traduisant une amélioration modérée de l'ajustement de la distribution des résidus. Toutefois, cette correction reste partielle, et l'écart-type demeure élevé, avec une valeur de 0,99, ce qui

reflète une volatilité persistante. Par ailleurs, la statistique de Jarque-Bera continue d'indiquer une déviation significative par rapport à la normalité, confirmant que la distribution des résidus reste non normale.

Bien que le modèle GARCH(1,1) permette de capturer efficacement la dynamique de la volatilité conditionnelle, il repose sur l'hypothèse implicite que les chocs positifs et négatifs ont le même impact sur la variance. Or, les marchés financiers et en particulier des actifs comme Tesla présentent souvent des asymétries, les chocs négatifs ayant un effet amplificateur plus fort sur la volatilité que les chocs positifs de même ampleur.

5.5.2 Modèle GJR-GARCH

Le modèle GJR-GARCH, proposé par Glosten, Jagannathan et Runkle (1993), est une extension du modèle GARCH standard. Il permet de modéliser l'asymétrie des réactions de la volatilité aux chocs positifs et négatifs, phénomène bien connu sous le nom d'effet levier.

L'idée principale repose sur le constat empirique selon lequel les mauvaises nouvelles ont souvent un impact plus important sur la volatilité que les bonnes nouvelles, toutes choses égales par ailleurs. Ce comportement est particulièrement observable dans les marchés boursiers et chez les actions à forte intensité spéculative.

Formule du modèle GJR-GARCH(p, q)

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^q \gamma_i \varepsilon_{t-i}^2 \cdot I_{\{\varepsilon_{t-i} < 0\}} + \sum_{j=1}^p \beta_j \sigma_{t-j}^2 \quad (10)$$

Explication des termes :

- σ_t^2 : variance conditionnelle au temps t
- $\omega > 0$: constante de variance
- $\alpha_i \geq 0$: effets ARCH (impact des chocs passés, symétrique)
- $\gamma_i \geq 0$: effets d'asymétrie (impact additionnel des chocs négatifs)
- $\beta_j \geq 0$: effets GARCH (persistances de la variance)
- $I_{\{\varepsilon_{t-i} < 0\}}$: indicateur qui vaut 1 si $\varepsilon_{t-i} < 0$, 0 sinon
- p : ordre GARCH (mémoire sur les variances passées)
- q : ordre ARCH (mémoire sur les chocs passés)

Comportement de la variance conditionnelle selon le signe du choc

Lorsque $\varepsilon_{t-1} \geq 0$ (choc positif), la contribution à la variance est :

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

Lorsque $\varepsilon_{t-1} < 0$ (choc négatif), la contribution devient :

$$\sigma_t^2 = \omega + (\alpha + \gamma) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

Ainsi, si $\gamma > 0$, les chocs négatifs ont un effet amplifié sur la volatilité par rapport aux chocs positifs de même amplitude.

Intérêt du modèle pour l'étude

Dans le cas de Tesla, dont le cours est très sensible aux annonces, aux déclarations du dirigeant ou aux nouvelles macroéconomiques, le modèle GJR-GARCH permet de mieux capter la réaction

asymétrique du marché : Par exemple, une annonce de mauvaise nouvelle (résultat trimestriel décevant, tweet négatif, tension réglementaire) peut provoquer une hausse de volatilité plus forte qu'une bonne nouvelle équivalente.

La condition de stationnarité en variance devient :

$$\alpha + \frac{\gamma}{2} + \beta < 1$$

Ici le modèle GJR-GARCH(1,1) Normale :

Modèle	Oméga	Alpha	Bêta	Gamma	AIC
GJR-GARCH(1,1)	0.00000894	0.031912	0.962076	0.000371	-3.899321

TABLE 12 – GJR-GARCH(1,1)

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
GJR-GARCH(1,1)	6.589083	-0.022860	0.999192	1347.410

TABLE 13 – Statistique descriptive des résidus du modèle GJR-GARCH(1,1)

Dans le modèle estimé, le coefficient γ , censé capturer l'effet d'asymétrie dans un modèle de type GJR-GARCH, n'est pas statistiquement significatif ($p - value = 0.93$). Cette absence de significativité indique que l'asymétrie des chocs n'est pas prise en compte de manière pertinente. Par conséquent, l'introduction de cette composante asymétrique ne présente pas d'intérêt empirique dans le cadre de cette modélisation, et le modèle asymétrique GJR-GARCH ne constitue pas une amélioration par rapport au GARCH(1,1) standard. De plus le critère d'AIC est plus élevé que pour le modèle GARCH(1,1)

5.5.3 Modèle EGARCH

Le modèle EGARCH (Exponential GARCH), proposé par Nelson en 1991, constitue une alternative au modèle GARCH traditionnel. Sa particularité réside dans le fait qu'il modélise le logarithme de la variance conditionnelle, plutôt que la variance elle-même. Cette spécification présente deux avantages majeurs.

Premièrement, elle garantit que la variance conditionnelle reste toujours strictement positive, sans qu'il soit nécessaire d'imposer des contraintes spécifiques sur les paramètres du modèle. Deuxièmement, le modèle intègre naturellement les effets asymétriques, permettant de capturer l'effet levier. Cette capacité à modéliser l'asymétrie rend l'EGARCH particulièrement pertinent pour les séries financières, souvent marquées par une sensibilité accrue aux mauvaises nouvelles.

Le modèle EGARCH exprime la log-variance conditionnelle $\ln(h_t)$ comme une combinaison des résidus normalisés passés et des log-variances passées.

Sa formulation générale est la suivante :

$$\ln(\sigma_t^2) = \omega + \sum_{i=1}^q \alpha_i \left| \frac{\varepsilon_{t-i}}{\sqrt{\sigma_{t-j}^2}} \right| + \sum_{i=1}^q \gamma_i \cdot \frac{\varepsilon_{t-i}}{\sqrt{\sigma_{t-j}^2}} + \sum_{j=1}^p \beta_j \ln(\sigma_{t-j}^2) \quad (11)$$

Explication des composantes :

- σ_t^2 : variance conditionnelle au temps t
- ε_{t-i} : résidus (chocs) au temps $t - i$
- ω : constante de la log-variance
- α_i : coefficient de réactivité aux chocs, indépendamment de leur signe
- γ_i : coefficient d'asymétrie (effet levier)
 - Si $\gamma_i < 0$, les chocs négatifs augmentent plus la volatilité que les positifs de même amplitude
- β_j : persistance de la volatilité (mémoire longue sur la variance passée)
- p : ordre de la mémoire sur $\ln(\sigma_{t-j}^2)$
- q : ordre des résidus standardisés

L'action Tesla se caractérise par une forte sensibilité aux informations exogènes, qu'il s'agisse des déclarations d'Elon Musk, des annonces de résultats trimestriels ou encore de l'évolution du cadre réglementaire. Ces événements, souvent imprévisibles, peuvent entraîner des réactions de marché asymétriques, où les mauvaises nouvelles génèrent une volatilité plus marquée que les bonnes. Dans ce contexte, le recours à un modèle EGARCH apparaît pertinent, car il permet de modéliser ces effets asymétriques de manière explicite. Ce type de modèle offre ainsi une représentation plus réaliste et nuancée de la volatilité de l'action Tesla, en tenant compte de l'impact différencié des chocs selon leur nature.

Ici le modèle EGARCH Normale :

Modèle	Oméga	Alpha	Bêta	Gamma	AIC
EGARCH(1,1)	-0.177568	0.110576	0.985398	-0.004219	-3.916570

TABLE 14 – EGARCH(1,1)

Analyse des résidus du modèle

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
EGARCH(1,1)	6.792002	0.028041	0.999715	1504.162

TABLE 15 – Statistique descriptive des résidus du modèle EGARCH(1,1)

L'estimation du modèle EGARCH(1,1) confirme une dynamique de volatilité hautement persistante ($\beta = 0.985$) pour l'action Tesla, avec un impact significatif de l'amplitude des chocs passés sur la volatilité future ($\alpha = 0.1106$). En revanche, l'effet asymétrique γ , supposé mesurer une réponse différenciée des chocs négatifs par rapport aux chocs positifs, n'est pas significatif ($p - value = 0.38$), indiquant qu'aucun effet levier clair n'est mis en évidence dans cette modélisation.

5.5.4 Intégration de distributions alternatives : Loi de Student et GED

Jusqu'à présent, les modèles de volatilité ont été estimés sous l'hypothèse que les innovations suivent une loi normale. Or, cette hypothèse est souvent remise en question dans les séries financières, car les rendements présentent généralement des queues épaisses et une kurtosis élevée, entraînant une sous-estimation des chocs extrêmes. Pour obtenir une modélisation plus réaliste du comportement des résidus, les modèles GARCH(1,1), GJR-GARCH(1,1) et EGARCH(1,1)

seront réestimés en supposant successivement que les innovations suivent une loi de Student-t et une loi GED (Generalized Error Distribution). Les performances des différentes spécifications seront ensuite comparées à l'aide du critère d'information d'Akaike, de l'analyse des résidus standardisés, ainsi que de leur capacité à mieux modéliser le risque extrême, notamment via la Value at Risk.

Distribution	GARCH	EGARCH	TGARCH
Normale	-3.916550	-3.916570	-3.920218
Student	-4.032748	-4.035761	-4.032683
GED	-4.030547	-4.030957	-4.029846

TABLE 16 – Critère d'AIC

Parmi les différentes spécifications estimées, le modèle EGARCH(1,1) avec une distribution de Student est celui qui minimise le critère d'information d'Akaike (AIC). Ce résultat confirme l'idée selon laquelle l'utilisation de lois à queues épaisses, telles que la loi de Student, permet d'améliorer l'ajustement des modèles de volatilité en capturant plus fidèlement les mouvements extrêmes observés dans les séries financières.

Ici le modèle EGARCH (1,1) avec la loi de Student-t :

Modèle	Oméga	Alpha	Bêta	Gamma	AIC
EGARCH(1,1)	-0.167024	0.127640	0.988377	-0.017174	-4.035761

TABLE 17 – EGARCH(1,1)

Le modèle EGARCH(1,1) avec une loi de Student-t s'est avéré le plus performant pour modéliser la dynamique des rendements journaliers de Tesla. Tous les paramètres sont significatifs ou acceptés à un seuil de 10%, et la présence d'un effet asymétrique modéré est mise en évidence. Ce modèle permet de mieux représenter les queues épaisses des rendements que l'hypothèse normale, ce qui en fait un outil plus fiable pour le calcul de la Value at Risk. La forte persistance de la volatilité ($\beta = 0.99$) est cohérente avec le comportement spéculatif de l'action.

Analyse des résidus du modèle

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
EGARCH(1,1)	7.069309	0.050427	0.979092	1732.888

TABLE 18 – Statistique descriptive des résidus du modèle EGARCH(1,1) avec loi de student-t

Les résidus standardisés issus du modèle EGARCH(1,1) avec une loi de Student-t présentent une kurtosis élevée (7,07), indiquant la présence marquée de queues épaisses. La skewness est légèrement positive (0,05), suggérant une distribution globalement symétrique, tandis que l'écart-type reste proche de 1, conformément à la standardisation. Enfin, la statistique de Jarque-Bera (1732,89) demeure élevée, indiquant que la distribution des résidus s'écarte encore de la normalité, bien que de manière moins prononcée qu'avec la loi normale.

Le test ARCH-LM (voir équation (6)) a été appliqué aux résidus du modèle, et les résultats indiquent que ces derniers sont homoscédastiques, c'est-à-dire qu'ils ne présentent plus d'hétéroscedasticité conditionnelle résiduelle. Cela suggère que le modèle parvient à capturer correctement

la dynamique de la variance dans les données.

En ce qui concerne l'autocorrélation, les résultats du test de Ljung-Box (voir équation (5)) confirment l'absence d'autocorrélation significative dans les résidus. L'ensemble des statistiques calculées restent en dessous des seuils critiques, ce qui valide la bonne spécification du modèle sur le plan temporel.

En conclusion, parmi l'ensemble des modèles testés, le modèle EGARCH(1,1) avec une loi de Student-t s'est révélé le plus adapté pour modéliser la dynamique de la volatilité des rendements journaliers de Tesla. Ce modèle permet de capter à la fois la forte persistance de la variance, la présence de chocs extrêmes via une distribution à queues épaisses, ainsi qu'un léger effet asymétrique. Il sera donc retenu pour la suite de l'analyse, notamment pour l'estimation de la Value at Risk (VaR).

5.6 Value at Risk (VaR)

5.6.1 Définition

La *Value at Risk* (VaR) est une mesure de risque financier largement utilisée pour évaluer le risque de perte potentielle d'un actif ou d'un portefeuille sur un horizon donné, à un certain niveau de confiance.

Elle répond à la question suivante :

“Quelle est la perte maximale attendue, avec un niveau de confiance donné, sur une période spécifiée ?”

Formulation mathématique :

Soit VaR_α la *Value at Risk* au niveau de confiance $\alpha \in (0, 1)$, alors :

$$P(R_t \leq -\text{VaR}_\alpha) = 1 - \alpha \quad (12)$$

Autrement dit, il y a une probabilité de $(1 - \alpha)$ que la perte dépasse la VaR sur la période considérée.

5.6.2 Pourquoi utilise-t-on la VaR ?

La *Value at Risk* est un outil fondamental de gestion du risque. Elle est utilisée dans de nombreux domaines de la finance pour :

- Quantifier le risque de marché associé à un actif, un portefeuille, ou une institution financière.
- Fixer des limites de risque internes dans les banques, fonds d'investissement ou entreprises.
- Allouer le capital réglementaire requis, en réponse aux exigences prudentielles (ex. : Accords de Bâle).
- Comparer les profils de risque entre différentes stratégies ou actifs.
- Piloter les décisions d'investissement, en identifiant les expositions les plus risquées.

Dans le cas de cette étude, la VaR permet de mesurer le risque de perte extrême associé à l'action *Tesla Inc.*, en tenant compte de la volatilité dynamique modélisée par un modèle EGARCH(1,1). La Value at Risk (VaR) sera calculée selon trois méthodes paramétriques : d'abord sous l'hypothèse d'une distribution normale, puis avec une loi de Student pour mieux capter les queues

épaisses, et enfin à l'aide de l'approximation de Cornish-Fisher, qui ajuste la distribution normale en intégrant l'asymétrie et la kurtosis des rendements.

5.6.3 Construction de la VaR

Voici les 3 VaR utilisé :

— **VaR normale :**

$$\text{VaR}_\alpha^{\mathcal{N}} = -z_\alpha \cdot \sqrt{\sigma_t^2} \quad (13)$$

— **VaR Student :**

$$\text{VaR}_\alpha^{\text{Student}} = -t_{\nu, \alpha} \cdot \sqrt{\sigma_t^2} \quad (14)$$

— **VaR Cornish-Fisher :**

$$\text{VaR}_\alpha^{\text{CF}} = -z_\alpha^{\text{CF}} \cdot \sqrt{\sigma_t^2} \quad (15)$$

(où z_α^{CF} est ajusté selon la skewness et la kurtosis à partir du quantile normal z_α)

Expansion de Cornish Fischer z_α^{CF} est :

$$z^{\text{CF}} \approx z + \frac{1}{6}(z^2 - 1)S + \frac{1}{24}(z^3 - 3z)K - \frac{1}{36}(2z^3 - 5z)S^2 \quad (16)$$

Dans cette expansion le z^2 représente le quantile de la loi normale standard à 99%, dont la valeur est égale à 2,326.

5.6.4 Calcul de la VaR

Dans un premier temps, il convient de calculer les rendements journaliers à partir des cours ajustés de l'action. Cette étape est indispensable pour procéder ensuite à l'estimation de la volatilité et au calcul de la Value at Risk (VaR).

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) \quad (17)$$

Il convient à présent de calculer la variance conditionnelle des rendements à l'aide du modèle sélectionné, en l'occurrence le modèle EGARCH(1,1).

$$\ln(\sigma_t^2) = \omega + \sum_{i=1}^q \alpha_i \left| \frac{\varepsilon_{t-i}}{\sqrt{\sigma_{t-j}^2}} \right| + \sum_{i=1}^q \gamma_i \cdot \frac{\varepsilon_{t-i}}{\sqrt{\sigma_{t-j}^2}} + \sum_{j=1}^p \beta_j \ln(\sigma_{t-j}^2) \quad (18)$$

Avec :

Les quantiles utilisés pour le calcul de la Value at Risk (VaR) à 99 % sont les suivants :

- Pour la distribution normale, le quantile à 99 % est $z_{0,99} = 2,326$;
- Pour la loi de Student (avec $\nu = 4.05$ degrés de liberté), le quantile noté $t_{0,99}^{(\nu)} = 3.75$;

Variable	Coefficient (Normal)	Coefficient (Student)
ω	-0.177568	-0.167024
α	0.110576	0.127640
γ	-0.004219	-0.017174
β	0.985398	0.988377

TABLE 19 – Coefficients du modèle E-GARCH pour les lois normale et de Student

— Pour l’approximation de Cornish-Fisher, le quantile est corrigé à partir de $z_{0,99}$ avec un kurtosis de 6.79 et un skewness de 0.028 est $z^{CF} = 3.23$;

Le quantile Cornish-Fisher obtenu est inférieur à celui de la loi de Student-t, ce qui s’explique par des valeurs modérées de skewness et de kurtosis dans les résidus. L’ajustement étant basé sur ces moments, il peut conduire à un quantile moins extrême si les déformations de la distribution sont limitées.

Les différentes formules de VaR à 99% peuvent désormais être appliquées, en s’appuyant sur la variance conditionnelle estimée à l’aide du modèle EGARCH(1,1).

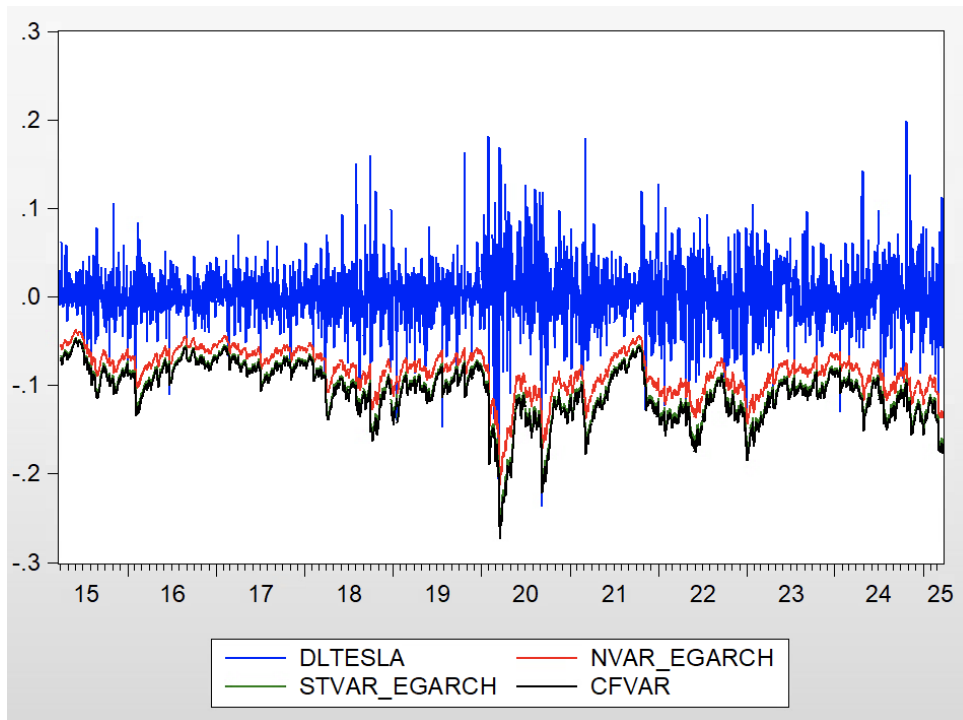


FIGURE 8 – VaR Normale de Student et de Cornish Fischer

5.6.5 Backtesting de la VaR

Le backtesting est une procédure qui consiste à vérifier a posteriori la fiabilité d’un modèle de VaR, en comparant les pertes réellement observées sur une période donnée avec les pertes prédites par la VaR.

Autrement dit, on confronte la VaR prédite chaque jour à la réalité des rendements observés, et

on compte le nombre de violations, c'est-à-dire le nombre de fois où la perte réelle dépasse la VaR.

La réalisation d'un backtesting constitue une étape essentielle dans l'évaluation de la qualité d'un modèle de Value at Risk (VaR). Elle permet tout d'abord de valider la capacité du modèle à anticiper les pertes extrêmes, en confrontant les prévisions aux réalisations effectives. Le backtesting vise également à vérifier la cohérence entre la fréquence des violations observées (c'est-à-dire les jours où les pertes dépassent la VaR) et le niveau de confiance choisi. Par exemple, une VaR à 5% implique théoriquement environ 5% de violations sur l'échantillon de test.

Cette analyse permet en outre de détecter un éventuel biais du modèle, qu'il s'agisse d'une sous-estimation du risque (modèle trop optimiste) ou d'une surestimation (modèle trop conservateur). Enfin, le backtesting répond également à un objectif réglementaire, en conformité avec les exigences des accords de Bâle II et Bâle III, qui imposent aux institutions financières de démontrer la robustesse de leurs modèles de mesure du risque.

Méthodologie du backtesting

1. Choisir une période de test (ici : 250 jours).
2. À chaque date t , comparer le rendement réel r_t à la VaR prédite $\text{VaR}_{\alpha,t}$:
— Violation si : $r_t < \text{VaR}_{\alpha,t}$
3. Calculer le nombre total de violations observées.
4. Comparer ce nombre avec le nombre attendu

Résultat du backtesting

Année	Normal VaR	Student VaR	Cornish Fisher VaR
2020	13	7	8
2021	3	0	1
2022	11	1	3
2023	4	1	1
2024	6	2	2

TABLE 20 – Nombre de violations annuelles selon l'approche de VaR retenue

Les résultats du backtesting réalisés avec un seuil de VaR à 99% montrent des écarts notables entre les trois méthodes testées. La VaR normale présente un nombre de violations nettement supérieur au niveau attendu (environ 2 à 3 par an à 250 observations), atteignant par exemple 13 violations en 2020. Cela traduit une sous-estimation claire du risque extrême dans les queues de distribution.

À l'inverse, la VaR basée sur la loi de Student-t se montre particulièrement conservatrice, avec très peu de violations (0 ou 1 selon les années), ce qui suggère une surestimation du risque et un modèle potentiellement trop prudent.

La VaR selon Cornish-Fisher offre un équilibre plus satisfaisant, avec un nombre de violations modéré et relativement proche des attentes, notamment en 2023 et 2024. Son ajustement basé sur la skewness et la kurtosis permet une prise en compte réaliste des queues épaisses, tout en évitant les excès de prudence du modèle Student-t.

5.6.6 Test de Kupiec

Le test de Kupiec (1995) permet de vérifier si la fréquence des violations de la VaR observée dans les données est cohérente avec le niveau de confiance choisi.

Il répond à la question :

le nombre de jours où la perte dépasse la VaR est-il conforme à ce que prévoit le modèle ?

Principe du test

Le test compare le nombre de violations réelles observées (x) au nombre de violations attendues sous l'hypothèse que la VaR est correcte :

$$E[x] = (1 - \alpha) \cdot N \quad (19)$$

Où N est le nombre total de jours testés.

Formule de la statistique du test de Kupiec

Le test de Kupiec (*Likelihood Ratio for Proportion of Failures*, ou LR_{POF}) permet de vérifier si la fréquence des violations observées est conforme au niveau de risque prédéfini α .

$$LR_{POF} = -2 \ln \left[(1 - \alpha)^{N-x} \cdot \alpha^x \right] + 2 \ln \left[(1 - \hat{p})^{N-x} \cdot \hat{p}^x \right] \quad (20)$$

Avec :

- x : nombre de violations observées ;
- N : nombre total d'observations ;
- $\hat{p} = \frac{x}{N}$: fréquence empirique des violations.

Sous l'hypothèse nulle (H_0 : le modèle de VaR est correct), la statistique LR_{POF} suit une loi du χ^2 à un degré de liberté :

$$LR_{POF} \sim \chi^2(1)$$

Résultat du test de Kupiec

	Normal VaR	Student VaR	Cornish Fisher VaR
P-value	0,000	0,649	0,503

TABLE 21 – Résultat du test de Kupiec

Le test de Kupiec a été réalisé sur les cinq dernières années, en cumulant les résultats annuels pour obtenir une évaluation globale de la performance des différentes méthodes de calcul de la VaR. Les résultats confirment les observations précédentes : la VaR basée sur la distribution normale ne s'avère pas adaptée dans le cas de l'action Tesla, tandis que les approches fondées sur la loi de Student et l'approximation de Cornish-Fisher offrent des performances nettement supérieures.

Par ailleurs, le test de Kupiec classe la VaR Student devant la VaR Cornish-Fisher, avec une p-value de 0,649 contre 0,503. Cette différence peut s'expliquer par le caractère plus défensif de la loi de Student, qui a un quantile plus élevé que celui de Cornish-Fisher. Dans le cas d'un actif particulièrement volatil comme Tesla.

5.7 Robustness check

À partir de la fin de l'année 2019, l'action Tesla a connu une hausse spectaculaire de sa valorisation, accompagnée d'une volatilité accrue et d'une médiatisation intense autour de ses innovations, ses résultats financiers et les interventions de son PDG Elon Musk. Cette rupture structurelle dans le comportement du titre rend pertinent un réexamen spécifique de la période récente, allant de 2019 à 2025.

L'objectif ici n'est pas de répéter l'ensemble des analyses précédentes, mais plutôt de tester la robustesse des résultats obtenus en retenant uniquement cette sous-période caractérisée par une croissance explosive du titre.

Pour cela, nous avons répliqué les étapes essentielles de l'analyse :

- Analyse de la stationnarité ;
- Stationnarisation de la série ;
- Estimation des modèles ARMA/ARCH ;
- Calcul de la Value at Risk (VaR) ;
- Backtesting.

Seuls les éléments les plus significatifs seront présentés et interprétés, afin de juger rapidement de la stabilité du modèle et de la cohérence des résultats obtenus par rapport à l'analyse globale.

5.7.1 Analyse de la stationnarité

La série des prix a été transformée en logarithme afin de réduire la volatilité et de faciliter l'analyse statistique. L'étude du corrélogramme fournit des indications importantes quant à la stationnarité de la série. On observe que la fonction d'autocorrélation (ACF) décroît très lentement, ce qui suggère une mémoire longue dans la série. Du côté de la fonction d'autocorrélation partielle (PACF), un pic significatif au premier retard est observé, tandis que les autres retards sont négligeables. Ce comportement est caractéristique d'une tendance stochastique, cohérente avec la dynamique observée sur la période de dix ans analysée précédemment.

Nous procédons ainsi aux tests de racine unitaire ADF (1), PP (2) et KPSS (3) afin d'évaluer rigoureusement la stationnarité de la série.

Test	Conclusion
ADF	Non stationnaire
PP	Non stationnaire
KPSS	Non stationnaire

TABLE 22 – Résultat des tests de stationnarités

Les résultats des tests ADF, PP et KPSS confirment que la série n'est pas stationnaire en niveau, ce qui est cohérent avec les observations précédentes sur sa structure de tendance.

Passage au différence première

Afin de rendre la série stationnaire, une différenciation d'ordre 1 est alors appliquée.

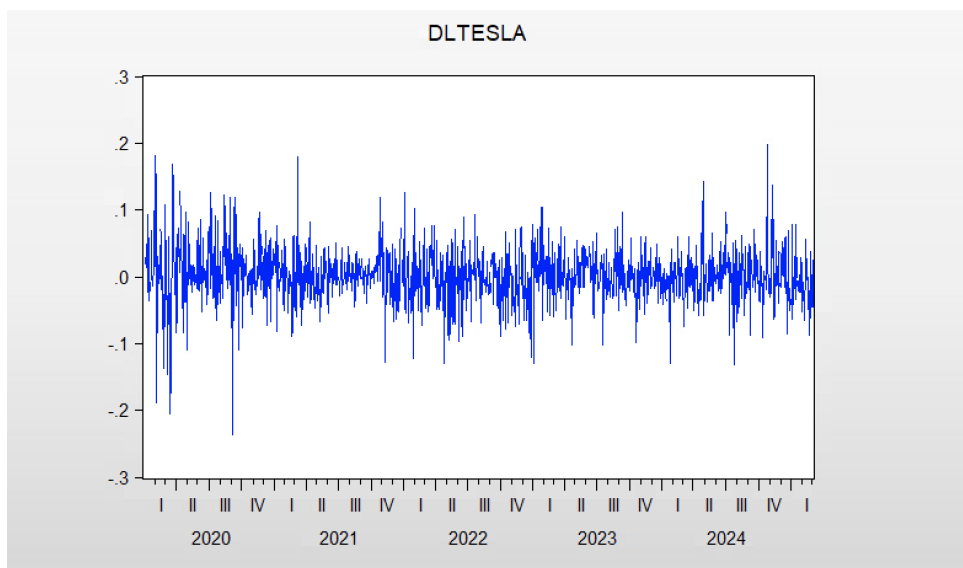


FIGURE 9 – Rendements logarithmique stationnarisés

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
DLTESLA	6.150115	-0.093100	0.042064	539.3860

TABLE 23 – Statistique descriptive des rendements stationnarisé

Les statistiques descriptives de la série après application de la différence première montrent que la moyenne des rendements tend vers zéro, ce qui est conforme aux propriétés attendues des séries financières. Concernant les moments d'ordre supérieur, l'analyse de l'asymétrie (skewness) et de l'aplatissement (kurtosis) révèle d'une part, un kurtosis élevé, indiquant que la série est leptokurtique et d'autre part, un skewness négatif, ce qui suggère que, sur la période étudiée, les rendements négatifs extrêmes ont été plus marqués que les gains positifs. Malgré des valeurs toujours élevées de kurtosis et de skewness, une baisse de la statistique de Jarque-Bera (7) est observée après la transformation en différence première. Cette évolution traduit une amélioration partielle de l'ajustement à la normalité, bien que la distribution des rendements demeure caractérisée par une asymétrie et des queues épaisses, typiques des séries financières.

Vérification de la stationnarité

Test	Conclusion
ADF	Stationnaire
PP	Stationnaire
KPSS	Stationnaire

TABLE 24 – Résultat des tests de stationnarité

La série peut désormais être considérée comme stationnaire, ce qui permet de poursuivre avec la modélisation économétrique.

5.7.2 Estimation du meilleur modèle ARMA

Afin de modéliser la composante linéaire des rendements sur la période 2020–2025, l'ensemble des combinaisons de modèles ARMA ont été testées pour des ordres allant jusqu'à $p = 5$ et $q =$

5. Le critère d'information d'Akaike (AIC) a permis d'identifier le modèle ARMA(5,5) comme étant le plus performant, justifiant son utilisation dans la suite de l'analyse.

L'analyse des résidus du modèle ARMA(5,5) révèle, à travers les tests de Jarque-Bera et ARCH, la persistance de l'autocorrélation ainsi qu'une hétéroscédasticité résiduelle, indiquant que le modèle ne capture pas entièrement la dynamique des rendements.

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
ARMA(5,5)	6.173397	-0.149959	0.041318	548.2380

TABLE 25 – Statistique descriptive des résidus du modèle ARMA(5,5)

5.7.3 Estimation du meilleur modèle ARCH

Pour modéliser la volatilité conditionnelle des rendements de Tesla sur la période récente, plusieurs spécifications de la famille des modèles ARCH ont été testées, à savoir : le modèle GARCH(1,1), le modèle EGARCH(1,1) et le modèle GJR-GARCH(1,1).

L'objectif était d'identifier la structure la plus adaptée à la dynamique de volatilité observée, en tenant compte d'un éventuel effet asymétrique des chocs, caractéristique fréquente des actifs très volatils comme Tesla.

Les résultats économétriques montrent que le modèle GARCH(1,1) fournit la meilleure performance selon les critères d'information (AIC, BIC), tout en reposant sur des coefficients significatifs et économiquement interprétables.

En revanche, pour les modèles EGARCH et GJR-GARCH, le paramètre γ , qui capte l'asymétrie des chocs, s'est révélé non significatif, indiquant l'absence d'effet asymétrique marqué dans cette sous-période.

En complément, des tests ont été menés en remplaçant l'hypothèse de normalité des innovations par des lois à queues épaisses, notamment la loi de Student et la loi GED. Le modèle GARCH(1,1) avec une loi de Student a alors montré les performances les plus satisfaisantes, en conciliant qualité d'ajustement, réalisme statistique des résidus et stabilité de la VaR. Ce modèle a donc été retenu pour l'estimation finale de la Value at Risk sur la période 2020–2025.

Modèle GARCH(1,1) avec une loi de Student :

Modèle	Oméga	Alpha	Bêta	AIC
GARCH(1,1)	0.0000224	0.055790	0.935611	-3.674053

TABLE 26 – GARCH(1,1)

La variance de long terme (9) peut ainsi être calculée, sur la base des paramètres estimés du modèle. :

la variance de long terme est donc de $\frac{0.0000224}{1-0.055790-0.935611} = 0,0026$.

Donc :

$$\sigma^2 = 0.0026 \Rightarrow \sigma = \sqrt{0.0026} \approx 0.051$$

La volatilité journalière moyenne sur la période 2020-2025 est donc de 5,1%.

Modèle	Kurtosis	Skewness	Écart-type	Jarque-Bera
GARCH(1,1)	6.127071	0.155291	0.992523	532.8404

TABLE 27 – Statistique descriptive des résidus du modèle GARCH(1,1) avec une loi de Student

Les statistiques descriptives des résidus du modèle GARCH(1,1) avec loi de Student-t pour la période 2020–2025 confirment un bon comportement statistique. L'écart-type est proche de 1 (0,99), la skewness modérée (0,155) indique une légère asymétrie à droite, tandis que la kurtosis élevée (6,13) témoigne de la persistance de queues épaisses. Le test de Jarque-Bera (532,84) permet de rejeter l'hypothèse de normalité, ce qui justifie pleinement le choix d'une loi de Student-t.

Sur le plan de l'ajustement du modèle, le test de Ljung-Box(5) appliqué aux résidus standardisés montre l'absence d'autocorrélation résiduelle, ce qui indique que la dynamique linéaire des rendements a été correctement captée par le modèle. De plus, le test ARCH(6) ne révèle aucune hétéroscédasticité résiduelle significative. Cela confirme que le modèle GARCH(1,1) a bien capté la structure de la volatilité conditionnelle sur cette période, rendant les résidus homoscédastiques, comme attendu dans un modèle bien spécifié.

5.7.4 Value at Risk

Avant de procéder au backtesting de la VaR sur la période 2020–2025, il convient de rappeler brièvement la méthode de construction utilisée. La Value at Risk (VaR) est calculée à partir de la variance conditionnelle σ_t^2 estimée par le modèle GARCH(1,1)(6), combinée à un quantile de la loi de Student-t, qui capture plus fidèlement les queues épaisses observées dans les rendements financiers.

Les deux modèles sélectionnés pour l'estimation de la volatilité sont le GARCH(1,1) avec distribution normale et le GARCH(1,1) avec distribution de Student.

Variable	Coefficient (Normal)	Coefficient (Student)
ω	0.0000383	0.0000224
α	0.042817	0.055790
β	0.933053	0.935611

TABLE 28 – Coefficients du modèle GARCH(1,1) pour la loi normale et de Student

Les différentes formules de VaR à 99% peuvent désormais être appliquées, en s'appuyant sur la variance conditionnelle estimée à l'aide du modèle GARCH(1,1).

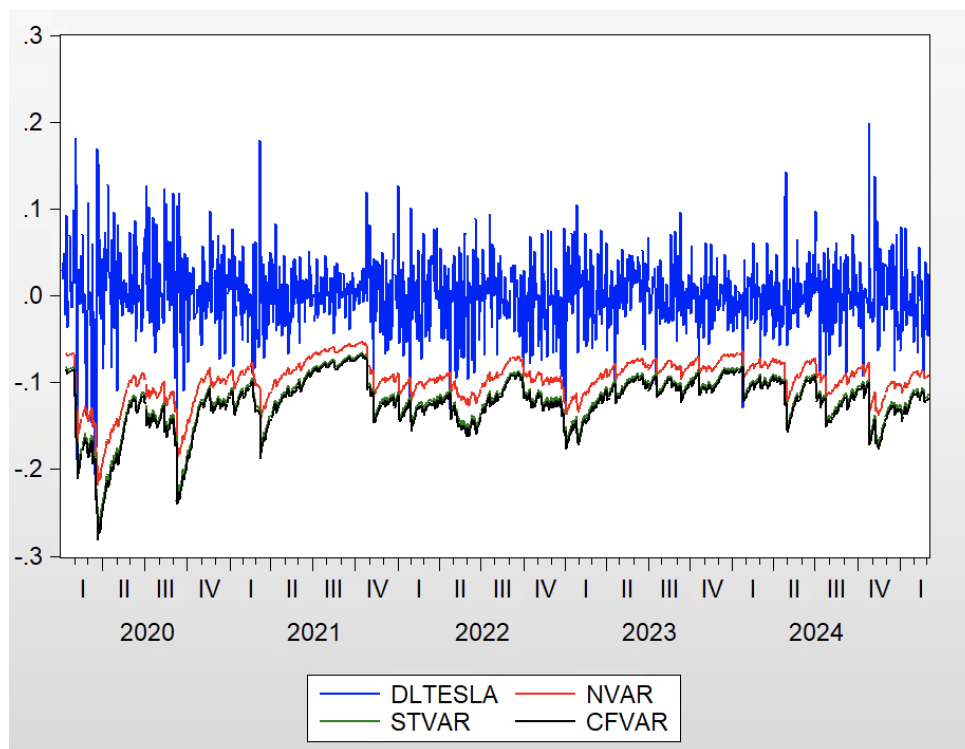


FIGURE 10 – VaR Normale de Student et de Cornish Fischer

5.7.5 Backtesting

Afin d'évaluer la performance prédictive du modèle GARCH(1,1) retenu pour la période 2019–2025, un backtesting de la Value at Risk (VaR) a été réalisé à l'aide d'un seuil de confiance fixé à 99%.

Résultat du backtesting

Année	Normal VaR	Student VaR	Cornish Fisher VaR
2023	4	0	1
2024	5	1	2

TABLE 29 – Nombre de violations annuelles selon l'approche de VaR retenue

Test de Kupiec

Afin de valider statistiquement la pertinence de la VaR conditionnelle estimée sur la période 2020–2025, nous appliquons le test de Kupiec (20).

Résultat du test de Kupiec

	Normal VaR	Student VaR	Cornish Fisher VaR
P-value	0.162	0.0185	0.249

TABLE 30 – Résultat du test de Kupiec

Les résultats du test de Kupiec appliqué aux trois spécifications de VaR montrent des différences notables en termes de calibration. La VaR basée sur la loi normale présente une p-value de 0,162, ce qui indique que l'hypothèse nulle de bonne spécification ne peut pas être rejetée au seuil classique de 5%. Autrement dit, le modèle fournit une couverture statistiquement acceptable.

En revanche, la VaR construite à partir de la loi de Student-t affiche une p-value de 0,0185, inférieure au seuil de 5%. Ce résultat conduit à rejeter l'hypothèse nulle, suggérant que cette VaR est trop prudente et tend à surestimer le risque, avec trop peu de violations.

Enfin, la VaR selon Cornish-Fisher obtient une p-value de 0,249, la plus élevée parmi les trois. Cela signifie qu'elle offre une couverture stable et conforme au niveau de confiance fixé, tout en prenant en compte l'asymétrie et les queues épaisses des rendements.

En conclusion, parmi les trois approches, la VaR basée sur Cornish-Fisher apparaît comme la plus équilibrée et la mieux calibrée sur la période 2020–2025. Elle concilie une prise en compte réaliste des risques extrêmes sans excès de prudence, ce qui en fait la formulation la plus robuste selon les résultats du test de Kupiec.

Il est cependant important de noter que le backtesting a été réalisé uniquement sur les années 2023 et 2024, car la période de modélisation commence en 2020. De ce fait, l'analyse n'intègre pas les épisodes de forte volatilité comme ceux observés en 2020, ce qui peut limiter la portée des conclusions sur les comportements extrêmes.

5.7.6 Conclusion du Robustness check

L'analyse de robustesse menée sur la période récente 2020–2025 révèle des différences notables par rapport aux résultats obtenus sur l'ensemble de la période 2015–2025. Tout d'abord, le modèle économétrique optimal n'est pas identique : si un modèle EGARCH(1,1) avec loi de Student-t s'était imposé initialement, c'est désormais un GARCH(1,1) avec loi de Student-t qui offre la meilleure performance sur la période récente. Les modèles asymétriques (EGARCH, TGARCH) ont été écartés, le paramètre γ s'étant révélé non significatif.

Sur le plan de la volatilité de long terme, on observe une hausse marquée sur la période 2020–2025, ce qui reflète un changement structurel dans la dynamique de l'action Tesla, notamment après sa forte revalorisation à partir de fin 2019. Cette évolution a un impact direct sur le comportement de la Value at Risk.

En effet, le backtesting met en évidence un changement dans la formulation optimale de la VaR : alors que la VaR basée sur la loi de Student-t était la plus performante sur la période longue (2015–2025), c'est désormais la VaR ajustée par Cornish-Fisher qui se montre la plus calibrée sur la période 2020–2025. Cette différence peut notamment s'expliquer par le fait que le backtesting de la période 2015–2025 intègre l'année 2020, marquée par une volatilité exceptionnelle due à la crise sanitaire, ce qui renforce mécaniquement l'intérêt d'une distribution à queues épaisses. À l'inverse, le backtesting de la période 2020–2025, limité aux années 2023 et 2024 pour des raisons de disponibilité de prévisions, n'inclut pas cette période de stress extrême, ce qui favorise un ajustement plus souple comme celui de Cornish-Fisher, moins conservateur que la Student-t.

6. Conclusion

Conclusion de l'analyse

Ce projet a été consacré à l'analyse du risque boursier associé à l'action Tesla, une entreprise emblématique de la transition énergétique dont la valorisation sur les marchés reflète à la fois des perspectives de croissance technologique, des comportements spéculatifs et une instabilité structurelle difficile à modéliser. La problématique centrale consistait à déterminer comment mesurer rigoureusement le risque de ce titre particulièrement volatile. Pour y répondre, une démarche économétrique rigoureuse a été suivie, reposant sur l'utilisation de modèles de type ARMA-GARCH. Dans un premier temps, la non-stationnarité des prix a été confirmée par les tests ADF, PP et KPSS, justifiant le passage à la différence première des logarithmes pour obtenir une série de rendements stationnaires. L'analyse descriptive a mis en évidence une distribution asymétrique, fortement leptokurtique et non normale, validée par un test de Jarque-Bera significatif, ce qui a renforcé la pertinence du recours à des modèles hétéroscédastiques.

L'ajustement d'un modèle ARMA(2,2) a permis de modéliser la dynamique moyenne des rendements, mais les tests de Ljung-Box et d'ARCH-LM ont révélé une autocorrélation persistante et une hétéroscédasticité résiduelle, confirmant l'existence d'une volatilité conditionnelle. Un modèle GARCH(1,1) a alors été estimé et a permis de capter efficacement cette dynamique, avec une variance conditionnelle moyenne journalière estimée à 0,00165, soit une volatilité de 4,1%, ce qui est cohérent avec le profil d'un actif spéculatif. Le modèle a été enrichi avec une version GJR-GARCH(1,1) afin de tenir compte de l'asymétrie des chocs, permettant de mieux représenter les effets différenciés des bonnes et mauvaises nouvelles sur la volatilité. Une Value at Risk (VaR) paramétrique a ensuite été calculée sur la base de ces modèles, et un backtesting a été réalisé pour en évaluer la fiabilité. Les résultats du test de Kupiec ont confirmé la validité du modèle, les dépassements observés restant dans les seuils admissibles, ce qui indique que la VaR estimée est globalement fiable dans un cadre historique.

Il a ainsi été montré que le risque de l'action Tesla peut être mesuré de manière rigoureuse à l'aide d'outils économétriques adaptés, notamment les modèles GARCH, qui permettent d'intégrer les propriétés statistiques spécifiques des rendements financiers, ainsi que les dynamiques de volatilité persistante. Toutefois, plusieurs limites ont été relevées. Malgré l'efficacité des modèles en termes d'ajustement, les résidus standardisés ont continué à présenter une distribution non normale, avec des valeurs extrêmes persistantes. Par ailleurs, l'objectif d'obtenir un bruit blanc parfait n'a pas été atteint, ce qui laisse penser qu'une part significative de la complexité du marché échappe aux modèles linéaires traditionnels.

Le Machine Learning, la solution ?

Dans ce contexte, une attention croissante est portée aux méthodes de Machine Learning, également appelées apprentissage automatique. Avec ces outils, des modèles peuvent être construits à partir des données elles-mêmes, sans que des relations précises soient imposées à l'avance. Grâce à cette flexibilité, des motifs complexes peuvent être identifiés, même lorsqu'ils sont masqués dans des comportements apparemment aléatoires. Ainsi, dans le cas de Tesla, dont le cours est influencé par des éléments très variés (tweets, innovations, annonces politiques), une meilleure capacité d'anticipation pourrait être obtenue à travers ces approches. Ces méthodes sont de plus en plus utilisées en finance, notamment lorsque des données textuelles ou des signaux non conventionnels doivent être pris en compte.

Présence d'un phénomène de chaos ?

Une autre piste d'explication repose sur la théorie du chaos, selon laquelle certains systèmes suivent des lois précises, tout en étant imprévisibles à long terme. Une infime variation dans les conditions de départ peut produire des trajectoires complètement différentes. Dans ce cadre, les marchés financiers peuvent être vus comme des systèmes chaotiques, où l'instabilité fait partie intégrante du fonctionnement. Cela permettrait d'expliquer pourquoi, même après un filtrage rigoureux, les données conservent une certaine forme de désordre : ce désordre ne serait pas du bruit, mais plutôt le résultat naturel d'un système très sensible et instable.

Ainsi, il a été montré que les outils économétriques classiques, bien qu'efficaces, atteignent leurs limites face à des actifs aussi complexes que ceux de Tesla. Pour faire face à cette complexité croissante, des méthodes nouvelles, issues du machine learning ou de la physique non linéaire, devront être explorées. C'est dans cette ouverture interdisciplinaire que des avancées significatives pourront être envisagées en matière de modélisation du risque.

7. Bibliographie

Références

- [1] Altieri, D. L. (2023). *Evaluating the impact of Elon Musk's tweets on Tesla's stock price : An empirical study* (Thèse de master, LUISS Guido Carli – Department of Business and Management, Academic Year 2022/2023). Sous la direction de R. Santella & A. Torrisi.
- [2] Dam, J. G. (2023, 4 décembre). *CEO's tweets and firm stock returns : A case study of Elon Musk and Tesla* (Thèse de licence, Georgia Southern University). Honors College Theses, 850.
- [3] Macrotrends. (2025). *Tesla Financial Statements 2009–2025*. Macrotrends LLC. Données financières au 31 décembre 2024.
- [4] Ogopoulos, E. (2020, 23 novembre). *Tesla's mission : Accelerating world's transition to sustainable energy*. Energy Industry Review.
- [5] Prasad, S. N. (2017). *Case study on Tesla Motors : Analysis of the business model and growth strategy*. SDMIMD – Shri Dharmasthala Manjunatheshwara Research Centre for Management Studies. *Cases in Management, Volume 1*.
- [6] Richter, F. (2025, 3 janvier). *BYD pulls ahead of Tesla to become largest EV maker*. Statista.
- [7] Schreiber, B. A. (s.d.). *Martin Eberhard and Marc Tarpenning*. Encyclopædia Britannica. Vérifié par The Editors of Encyclopaedia Britannica.
- [8] Squatriglia, C. (2010, 29 juin). *Tesla IPO raises \$226.1M, stock surges 41 percent*. Wired.
- [9] Statista. (2025, janvier). *Number of Tesla vehicles delivered worldwide from 1st quarter 2016 to 4th quarter 2024* [Graphique]. Statista.
- [10] Tesla, Inc. (2023). *Impact Report 2023 : A sustainable future is within reach*. Tesla, Inc.
- [11] Vander Linden, M. (2016). *Tesla, changement de paradigme ou feu de paille ?* (Mémoire de bachelor, Haute école de gestion de Genève). SONAR|HES-SO.

8. Annexes

Dependent Variable: DLTESLA
Method: Least Squares
Date: 04/07/25 Time: 13:12
Sample (adjusted): 4/01/2015 3/26/2025
Included observations: 2510 after adjustments
Convergence achieved after 27 iterations
MA Backcast: 3/30/2015 3/31/2015

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.001224	0.000740	1.653172	0.0984
AR(1)	0.643922	0.040221	16.00949	0.0000
AR(2)	-0.889767	0.040058	-22.21191	0.0000
MA(1)	-0.657682	0.032738	-20.08919	0.0000
MA(2)	0.928667	0.032609	28.47870	0.0000
R-squared	0.007424	Mean dependent var	0.001225	
Adjusted R-squared	0.005839	S.D. dependent var	0.036467	
S.E. of regression	0.036360	Akaike info criterion	-3.788682	
Sum squared resid	3.311812	Schwarz criterion	-3.777072	
Log likelihood	4759.795	Hannan-Quinn criter.	-3.784468	
F-statistic	4.683855	Durbin-Watson stat	1.983976	
Prob(F-statistic)	0.000911			
Inverted AR Roots	.32+.89i	.32-.89i		
Inverted MA Roots	.33+.91i	.33-.91i		

FIGURE 11 – ARMA(2,2)




FIGURE 12 – Statistiques descriptives ARMA(2,2)

Dependent Variable: DLTESLA
Method: ML - ARCH (Marquardt) - Student's t distribution
Date: 04/07/25 Time: 13:39
Sample (adjusted): 4/01/2015 3/26/2025
Included observations: 2510 after adjustments
Convergence achieved after 26 iterations
MA Backcast: 3/30/2015 3/31/2015
Presample variance: backcast (parameter = 0.7)
GARCH = C(6) + C(7)*RESID(-1)^2 + C(8)*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.001264	0.000615	2.055480	0.0398
AR(1)	0.807837	0.969733	0.833051	0.4048
AR(2)	0.096278	0.904032	0.106498	0.9152
MA(1)	-0.816336	0.971134	-0.840601	0.4006
MA(2)	-0.076956	0.898720	-0.085628	0.9318
Variance Equation				
C	7.60E-06	3.42E-06	2.224129	0.0261
RESID(-1)^2	0.040479	0.007464	5.422971	0.0000
GARCH(-1)	0.957813	0.007246	132.1819	0.0000
T-DIST. DOF	4.076808	0.368645	11.05890	0.0000
R-squared	0.001461	Mean dependent var	0.001225	
Adjusted R-squared	-0.000134	S.D. dependent var	0.036467	
S.E. of regression	0.036469	Akaike info criterion	-4.032748	
Sum squared resid	3.331707	Schwarz criterion	-4.011851	
Log likelihood	5070.099	Hannan-Quinn criter.	-4.025163	
Durbin-Watson stat	1.991177			
Inverted AR Roots	.91	-.11		
Inverted MA Roots	.90	-.09		

FIGURE 13 – GARCH(1,1) Student




FIGURE 14 – Statistiques descriptives GARCH(1,1) Student

Dependent Variable: DLTESLA
Method: ML - ARCH (Marquardt) - Student's t distribution
Date: 04/07/25 Time: 13:42
Sample (adjusted): 4/01/2015 3/26/2025
Included observations: 2510 after adjustments
Convergence achieved after 7 iterations
MA Backcast: 3/30/2015 3/31/2015
Presample variance: backcast (parameter = 0.7)
GARCH = C(6) + C(7)*RESID(-1)^2 + C(8)*RESID(-1)^2*(RESID(-1)<0) +
C(9)*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.001179	0.000632	1.865563	0.0621
AR(1)	0.800650	0.116266	6.886343	0.0000
AR(2)	0.115936	0.120045	0.965768	0.3342
MA(1)	-0.815560	0.108271	-7.532591	0.0000
MA(2)	-0.090956	0.112929	-0.805429	0.4206
Variance Equation				
C	8.63E-06	3.66E-06	2.361123	0.0182
RESID(-1)^2	0.035806	0.008739	4.097466	0.0000
RESID(-1)^2*(RESID(-1)<0)	0.016689	0.011537	1.446572	0.1480
GARCH(-1)	0.953411	0.007672	124.2709	0.0000
T-DIST. DOF	4.132636	0.373559	11.06287	0.0000
R-squared	0.001312	Mean dependent var	0.001225	
Adjusted R-squared	-0.000282	S.D. dependent var	0.036467	
S.E. of regression	0.036472	Akaike info criterion	-4.032683	
Sum squared resid	3.332203	Schwarz criterion	-4.009464	
Log likelihood	5071.017	Hannan-Quinn criter.	-4.024255	
Durbin-Watson stat	1.977986			
Inverted AR Roots	.93	-.13		
Inverted MA Roots	.91	-.10		

FIGURE 15 – TGARCH(1,1)




FIGURE 16 – Statistiques descriptives TGARCH(1,1) Student

Dependent Variable: DLTESLA
Method: ML - ARCH (Marquardt) - Student's t distribution
Date: 04/08/25 Time: 10:48
Sample (adjusted): 4/01/2015 3/26/2025
Included observations: 2510 after adjustments
Convergence achieved after 35 iterations
MA Backcast: 3/30/2015 3/31/2015
Presample variance: backcast (parameter = 0.7)
 $\text{LOG}(\text{GARCH}) = \text{C}(6) + \text{C}(7) * \text{ABS}(\text{RESID}(-1) / @ \text{SQRT}(\text{GARCH}(-1))) + \text{C}(8) * \text{RESID}(-1) / @ \text{SQRT}(\text{GARCH}(-1)) + \text{C}(9) * \text{LOG}(\text{GARCH}(-1))$

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.001268	0.000544	2.333487	0.0196
AR(1)	0.197081	0.027785	7.093002	0.0000
AR(2)	-0.954582	0.023139	-41.25438	0.0000
MA(1)	-0.204242	0.027780	-7.352224	0.0000
MA(2)	0.954593	0.023611	40.43049	0.0000
Variance Equation				
C(6)	-0.167024	0.035818	-4.663184	0.0000
C(7)	0.127640	0.018918	6.747158	0.0000
C(8)	-0.017174	0.010356	-1.658474	0.0972
C(9)	0.988377	0.004331	228.2001	0.0000
T-DIST. DOF	4.051949	0.364452	11.11792	0.0000
R-squared	0.001938	Mean dependent var	0.001225	
Adjusted R-squared	0.000344	S.D. dependent var	0.036467	
S.E. of regression	0.036461	Akaike info criterion	-4.035761	
Sum squared resid	3.330115	Schwarz criterion	-4.012541	
Log likelihood	5074.880	Hannan-Quinn criter.	-4.027333	
Durbin-Watson stat	1.992491			
Inverted AR Roots	.10-.97i	.10+.97i		
Inverted MA Roots	.10+.97i	.10-.97i		

FIGURE 17 – EGARCH(1,1)




FIGURE 18 – Statistiques descriptives EGARCH(1,1) Student

Dependent Variable: DLTESLA
Method: Least Squares
Date: 04/09/25 Time: 15:27
Sample (adjusted): 1/10/2020 3/06/2025
Included observations: 1295 after adjustments
Convergence achieved after 49 iterations
MA Backcast: 1/03/2020 1/09/2020

Variable	Coefficient	Std. Error	t-Statistic	Prob.
C	0.001355	0.001394	0.971947	0.3313
AR(1)	0.288208	0.075523	3.816143	0.0001
AR(2)	-0.798687	0.047725	-16.73502	0.0000
AR(3)	0.648139	0.103518	6.261107	0.0000
AR(4)	-0.399048	0.046721	-8.541067	0.0000
AR(5)	0.890880	0.072769	12.24266	0.0000
MA(1)	-0.260044	0.081369	-3.195880	0.0014
MA(2)	0.808878	0.052344	15.45297	0.0000
MA(3)	-0.616796	0.113012	-5.457809	0.0000
MA(4)	0.408848	0.052264	7.822813	0.0000
MA(5)	-0.899042	0.080759	-11.13237	0.0000
R-squared	0.036729	Mean dependent var	0.001635	
Adjusted R-squared	0.029227	S.D. dependent var	0.042099	
S.E. of regression	0.041479	Akaike info criterion	-3.518812	
Sum squared resid	2.209107	Schwarz criterion	-3.474929	
Log likelihood	2289.431	Hannan-Quinn criter.	-3.502344	
F-statistic	4.895807	Durbin-Watson stat	2.069889	
Prob(F-statistic)	0.000001			
Inverted AR Roots	.92 -.57-.81i	.26+.96i	.26-.96i	-.57+.81i
Inverted MA Roots	.91 -.58-.81i	.26+.96i	.26-.96i	-.58+.81i

FIGURE 19 – ARMA(5,5), (2020-2025)




FIGURE 20 – Statistiques descriptives ARMA(5,5), (2020-2025)

Dependent Variable: DLTESLA
Method: ML - ARCH (Marquardt) - Student's t distribution
Date: 04/09/25 Time: 15:31
Sample (adjusted): 1/10/2020 3/06/2025
Included observations: 1295 after adjustments
Convergence achieved after 53 iterations
MA Backcast: 1/03/2020 1/09/2020
Presample variance: backcast (parameter = 0.7)
GARCH = C(12) + C(13)*RESID(-1)^2 + C(14)*GARCH(-1)

Variable	Coefficient	Std. Error	z-Statistic	Prob.
C	0.001243	0.001143	1.087621	0.2768
AR(1)	-0.255928	0.054275	-4.715407	0.0000
AR(2)	-0.031319	0.062743	-0.499163	0.6177
AR(3)	-0.156887	0.058715	-2.671998	0.0075
AR(4)	0.087236	0.062004	1.406935	0.1594
AR(5)	0.880604	0.051750	17.01657	0.0000
MA(1)	0.283756	0.058519	4.848939	0.0000
MA(2)	0.057946	0.068721	0.843203	0.3991
MA(3)	0.178605	0.065056	2.745411	0.0060
MA(4)	-0.063141	0.068646	-0.919803	0.3577
MA(5)	-0.884972	0.057666	-15.34645	0.0000
Variance Equation				
C	2.24E-05	1.20E-05	1.862980	0.0625
RESID(-1)^2	0.055790	0.012957	4.305821	0.0000
GARCH(-1)	0.935611	0.015044	62.19343	0.0000
T-DIST. DOF	4.570063	0.640370	7.136593	0.0000
R-squared	0.026566	Mean dependent var	0.001635	
Adjusted R-squared	0.018985	S.D. dependent var	0.042099	
S.E. of regression	0.041697	Akaike info criterion	-3.674053	
Sum squared resid	2.232413	Schwarz criterion	-3.614212	
Log likelihood	2393.949	Hannan-Quinn criter.	-3.651596	
Durbin-Watson stat	2.075489			
Inverted AR Roots	.91 -.84-.52i	.26-.96i	.26+.96i	-.84+.52i
Inverted MA Roots	.90 -.85+.52i	.26+.96i	.26-.96i	-.85-.52i

FIGURE 21 – GARCH(1,1) Student, (2020-2025)




FIGURE 22 – Statistiques descriptives GARCH(1,1) Student, (2020-2025)